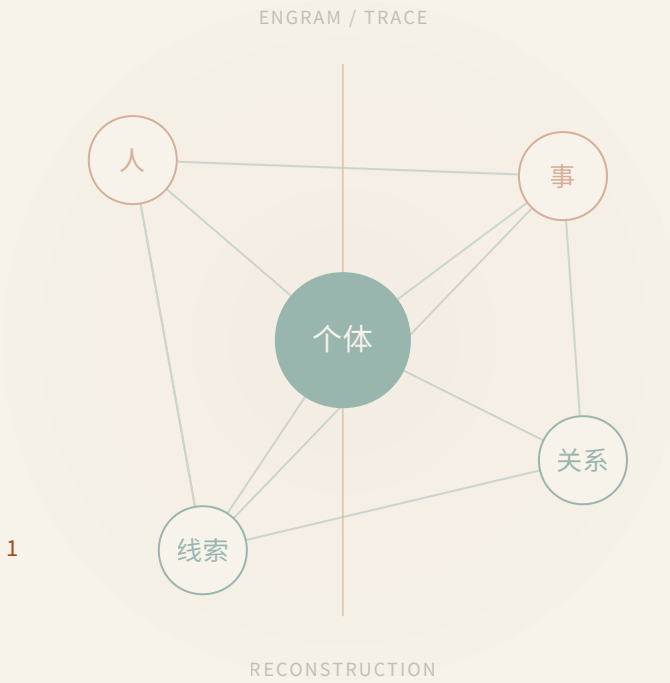



DOUBLE-BRAIN SYSTEM · VERSION 2.1

# 双脑系统

## 多模型协同认知框架 · 从神经机制到模拟方案

> 这套方案的第一目的，不是做一套记忆库，而是让多个模型分工，把主脑每一轮要读的上下文压到最小。记忆不是仓库，而是让主脑在关系中做出更好判断的基础设施；编码、巩固、提取、再巩固、遗忘、决策与社会关系记忆，都是这条主线上的环节。

**版本** 2.1 · 技术方案　**日期** 2026 年 10 月　**定位** 《双脑系统》版本一的机制深化与工程化

| 10 | 8 | 6 | 4±1 |
|---|---|---|---|
| 后台角色 | 记忆存储 | 运行闭环 | 上下文槽位 |

FIG. 0 — THE RELATIONAL ENGRAM

目录 · CONTENTS


导论

00 一页纸方案

部 I · 机理

01 记忆不是存储：一套动态系统

02 从神经机制到计算原语

部 II · 架构

03 双脑架构：一个主脑，十个后台

3.6 运行时解剖学：从权限到硬边界

3.7 主导权：三个时间尺度与批准权

04 数据模型：事件、人物、关系、解释

05 六个运行闭环

部 III · 模拟

06 关键机制的模拟细节

07 多模型分工与上下文经济

部 IV · 验证与落地

08 评估：像记忆，而不是像数据库

09 MVP 与迭代路线

10 风险、边界与开放问题

附录

A 术语表

B 关键文献

C 数据字典与伪代码


阅读建议：先读 00（一页纸）、03（架构）与 09（MVP），建立整体判断；再回到 01–02（机理）与 06（算法细节）；第 08 章给出可验证的评估口径。

00 · EXECUTIVE SUMMARY

# 一页纸方案

先把结论放在前面：要模拟的不是“记忆”，而是记忆与决策之间的那条回路。

这套方案的第一目的，不是再做一套记忆库，而是让多个模型分工，把主脑每一轮要读的上下文压到最小，同时让进入上下文的信息更准。人脑不是一台大模型，而是许多功能单元分别处理、再由一个主脑统一判断；记忆存在的理由，是帮助个体认清与他人的关系与位置。以下所有机制，都服务于这条主线：**分工 → 情境 → 判断 → 关系与记忆更新**。

主线

**多模型分工 → 后台编译情境 → 主脑判断 → 关系与记忆更新**。记忆不是目的；它是让主脑在关系中做出更好判断的基础设施。

核心命题

**记忆的单位是事件，不是 token；记忆存在的理由是社会关系；上下文的单位是此刻需要的那几块，不是全部记忆；KPI 不是“存了多少”，而是“关系中的下一次判断少犯多少错”**。

> 第一性抽象
>
> **事件影响状态；状态影响判断与记忆**。人、机器、大模型共用同一条准则，差别只在状态载体与更新速度。状态必须拆成 `state_view`（进上下文，是提示词）与 `state_params`（进运行时，真正改变检索、预算、门控与写入）。

> 第 0 条
>
> **分工，不是堆模型**。多个模型各处理一小片，再由一个主脑统一判断；否则只是把一个大上下文换成一群小上下文。

## 十条设计原则

01 **多系统，不是多副本**。情景记忆、语义记忆、程序记忆、工作记忆、关系记忆分别存储、分别更新；同一次经历可以同时产生三类积累，但共享同一个事件源。

02 **编码有门槛**。不是所有输入都值得记。显著性、目标相关、社会影响、情绪强度、预测误差共同决定是否分配“印迹”。

03 **索引与内容分离**。海马体不存整段电影，只存稀疏索引；系统也不把全文塞进索引，只存指针、稀疏码与关联权重。

04 **巩固是离线蒸馏**。白天编码，夜间重放：扫描—聚类—重放—抽象—合并—修剪，把情景蒸馏为语义与技能。

05 **提取是重建**。每次回答都是从碎片重新组装的叙事，必须带来源；没有来源就弃权，而不是编造。

06 **再巩固是版本化**。每次提取都可能改写记忆；新版本追加，旧版本保留，永不覆盖。

07 **遗忘是功能**。衰减、干扰消解、索引修剪共同降低噪声；未完成承诺与安全关键信息豁免。

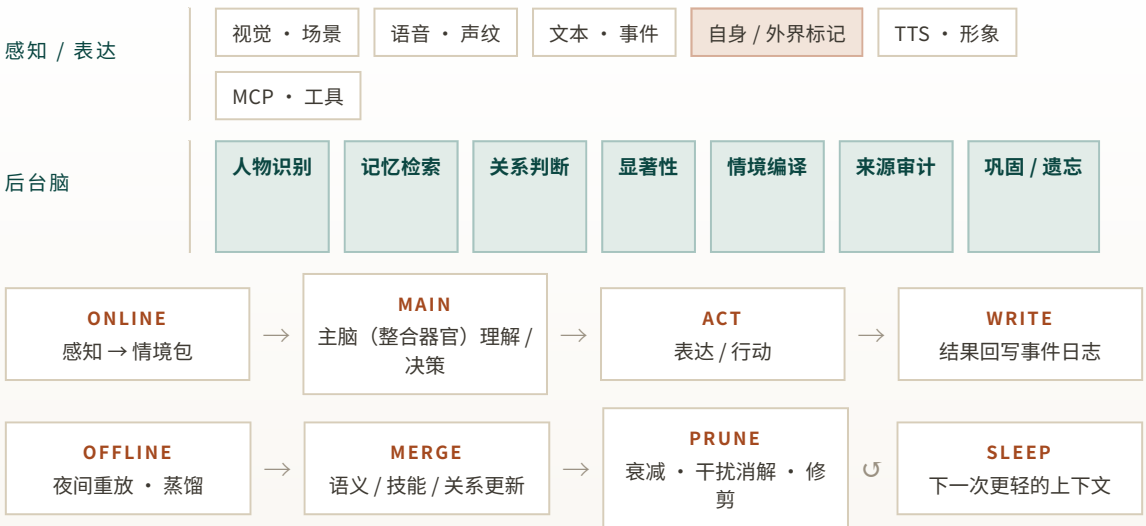
08 **决策分双系统**。熟悉、低风险、时间紧时走习惯快路；陌生、高风险、需要解释时走模型化推演。仲裁权在主脑。

09 **关系是记忆的主索引**。人物—事件双向唤起；关系多维、不对称、带依据、随时间与经历更新。

10 **只有一个整合中心——它属于整个有机体**。后台只编译情境，不提供建议、不行动、不代替决策；外部行动身份属于有机体，主脑在授权范围内代签。

> 第十一、十二条（隐含）
>
> **边界是材料，不是政策；批准权即主导权**。没有运行时隔离的宪法只是软约束；事实可后台写，价值/角色、目标、习惯规则只提案，由主脑作为整合器官批准，宪法核心需用户与主脑平等共签。执行机制见 3.6–3.7 节。

图 0 · 一页纸架构




实线为在线闭环，虚线为离线闭环。后台可读记忆库、提交写入候选，但只能通过“情境包”影响主脑；外部行动身份属于有机体，主脑在授权范围内代签。

## 与版本一/二的关系

版本一/二确立了“一个整合中心、后台脑、知识/记忆/技能、关系与经历、双脑决策”的骨架。当前版本保留这些骨架，但有三类变化：**保留并展开、修订、新增**。修订与新增必须标明，避免把后来的讨论当成原始口径。

表 0 · 从版本一/二到当前版本：保留、修订、新增

| 原始口径（V1/V2） | 当前版本的展开 | 工程落点 |
| --- | --- | --- |
| **主脑没有上下文** | 主脑是无状态推理过程，每轮从情境包重建；后台是有状态记忆系统 | ContextPacket 作为唯一跨层接口；主脑不持久化对话历史 |
| **后台脑筛选记忆** | 显著性门控 + 海马索引 + 模式分离/完成 + 情境编译 | 编码管线、检索管线、4±1 槽位、惰性展开 |
| **知识 / 记忆 / 技能** | 互补学习系统：快速情景存储 + 慢速语义抽象 + 程序化技能 | 事件日志、语义图谱、技能库，共享 event_id |
| **关系与经历** | 人物—事件双向图；关系多维、不对称、带证据 | Person / Participation / Relationship 三类记录 |
| **事实与解释分开** | 来源监控 + 解释版本链 + 证据按事件计数 | Interpretation 层；`evidence_count = distinct event_id` |
| **记忆淡化** | 艾宾浩斯衰减 × 关系强度 × 未来效用；未完成承诺豁免 | 保留率公式、冷归档、索引修剪 |
| **习惯像缓存** | model-free 快路；只缓存情境模板与技能，不缓存“决定” | Habit 表 + 主脑仲裁，后台不越权 |
| **修订 · 整体才是个体** | 整合中心是有机体整体的整合属性；主脑是整合与签署器官，不是个体 | 3.1 / 3.6；行动身份属于有机体，主脑代签 |
| **修订 · 习惯规则需批准** | 后台可按频率提案，但习惯规则生效需主脑批准；后台不直接改写未来自我 | 3.7 / 6.7；Habit 状态 candidate / ratified |
| **新增 · 运行时边界** | 后台无网络、无工具、无持久身份；行动权只属于有机体 | 3.6；权限矩阵、红队清单 |
| **新增 · 批准账本** | 构成性变更走提案—批准—冷却—回滚；账本可验证 | 3.7；Constitution / Ledger |
| **新增 · 证据账本与模拟边界** | 回想不增加证据；冲突并列；模拟永不写成事实 | 4.6 / 6.7.2；evidence_count / simulation schema |
| **新增 · 组合式重放** | 从多事件抽取人物/地点/动作/目标原语，按槽位组合未来候选；标记 simulation，不写事实 | 6.2.1；primitives.py / simulation.py |
| **新增 · 治理形态** | 陪伴型：用户与主脑平等共签；工程型：用户最高权限 | 3.7.1；ConstitutionStore(mode) |

> 阅读路径
>
> 主线：0 → 1.9 → 3.1–3.3 → 4.2–4.4 → 5 → 6.8 → 7。机制背景：1–2、6；工程约束：3.6–3.7、9.4、10，可后读。这样不会把“治理与安全”误当成记忆主线。

PART I · MECHANISM

# 先理解脑，再设计系统

记忆不是一块可以随意读写的硬盘。它是一组相互竞争、相互抑制、又相互补足的系统：有的负责快速绑定，有的负责慢速抽象；有的负责当下维持，有的负责长期修剪。要模拟它，先要知道每一部分在解决什么问题。

01 记忆不是存储　　02 从机制到计算原语

01 · NEUROSCIENCE OF MEMORY

# 记忆不是存储：一套动态系统

编码、巩固、提取、再巩固、遗忘——五个阶段，五套不同的计算问题。

如果把记忆比作图书馆，你会自然想到“藏书、索引、借阅”。但脑不是这样。脑没有一本书是原样保存的；每一次“借阅”都会重新装订，甚至改写几页。脑更像一座不断重排的档案馆：入库有门槛，编目靠稀疏索引，夜间有专门的整理员把相似卷宗合并成摘要，而读者每次取阅都会留下新的批注。理解这套流程，比记住任何一个脑区名字都重要。

## 1.1 多系统版图：记忆不是一种能力

长时记忆分**陈述性**（情景：一个人经历过什么；语义：一个人知道什么）与**非陈述性**（程序、启动、条件反射、习惯化），另有容量极小的工作记忆与带情绪/社会属性的关系记忆。它们依赖不同脑系统，写入与读取规律不同（Squire 2004；Eichenbaum 2004）。设计的第一条不是“建一个更大的库”，而是“建几个写入速率与读取规则不同的库”。

表 1 · 记忆系统速览

| 系统 | 回答的问题 | 写入 / 读取特征 |
|---|---|---|
| **情景** | 何时、何地、与谁经历了什么 | 快速、稀疏、单次即可写入；依赖索引与模式分离 |
| **语义** | 世界是什么，概念如何关联 | 慢速、重叠、统计学习；靠重复与睡眠蒸馏 |
| **程序** | 一件事怎么做 | 渐进、自动化；错误驱动与强化 |
| **关系** | 这人是谁，我们经历过什么 | 人物—事件双向绑定；多维、不对称、带证据 |

## 1.2 编码：显著性门控与海马索引

编码先过注意与显著性门：情绪唤醒调节海马与皮层编码（McGaugh 2000；Cahill & McGaugh 1998），意外的好结果被标记为值得学习（Schultz et al. 1997）。海马不存整段经历，只提供**稀疏索引**（Teyler & DiScenna 1986）；齿状回做**模式分离**，CA3 做**模式完成**。分子层面，LTP 的 NMDA 巧合检测、CaMKII 与 AMPA 变化，需要转录翻译才能持久（Bliss & Lomo 1973；Malenka & Bear 2004；Davis & Squire 1984）。2024 年小鼠研究还发现，CA1 印迹细胞在编码时出现 DNA 双链断裂与 TLR9–NF-κB 信号，提示写入伴随代价与修复（Jovasevic et al. 2024；仍属小鼠单一范式）。对系统：**显著性门、索引门、分配门**，缺一就会退化成全量日志。

## 1.3 巩固：睡眠重放与图式同化

**突触巩固**在分钟–小时尺度稳定早期 LTP（Frey & Morris 1997）；**系统巩固**在天–年尺度把骨架交给新皮层，海马保留索引与细节（Squire & Alvarez 1995；Nadel & Moscovitch 1997）。睡眠中慢振荡、纺锤波与海马涟漪耦合，重放白天序列（Staresina 2024；Schreiner et al. 2024）；重放优先高显著性、高预测误差、与未完成目标相关的序列，也会反向重放或模拟未发生的路径（Foster &

Wilson 2006；Pfeiffer & Foster 2013）。图式兼容的信息更快被同化（Tse et al. 2007）。对系统：**要点抽象与细节保留两条路径**；先判断“与哪块图式兼容”，再决定写多深。

### 1.4 提取：模式完成与重建

提取不是回放，而是**重建**：用当前目标、情绪与知识把碎片拼成自洽故事（Bartlett 1932；Loftus & Palmer 1974）。CA3 模式完成让部分线索召回整段记忆，但也会过度补全：激活印迹细胞足以制造“假经历”（Ramirez et al. 2013）。编码特异性决定线索是否有效（Tulving & Thomson 1973）；**来源监控**决定这是亲历、听说还是想象（Johnson et al. 1993）。对系统：多维线索（人物、地点、时间、情绪、目标）+ 来源标签；没有来源的检索等于没有防线。

### 1.5 再巩固：提取即改写

提取会把记忆推回不稳定状态，随后需要再次巩固（Nader et al. 2000）。它不是“每次回忆都必然改写”：记忆年龄、强度、预测误差与情境新颖性决定是否更新（Nader & Hardt 2009）；临床用普萘洛尔削弱恐惧记忆仍属研究阶段（Kindt et al. 2009）。对系统：**检索即写，但写新版本，不覆盖旧版本**。

> **记忆的稳定性，不是“不变”，而是“可被安全地更新”。**
>
> 再巩固给系统的启示：检索即写，但写的是新版本，不是覆盖旧版本。

---

### 1.6 遗忘：不是失败，是修剪

艾宾浩斯（Ebbinghaus 1885）用无意义音节画出了第一条遗忘曲线：记忆在最初几小时到几天内快速下降，之后趋于平缓。但“遗忘=衰退”只是最表层的解释。更完整的图景是：遗忘同时来自**衰退、干扰、提取失败与主动抑制**，而它本身具有适应价值。

理查兹与弗兰克兰（Richards & Frankland 2017）提出，遗忘是一种“适应性印迹细胞可塑性”：记忆的痕迹还在，但变得难以提取；这降低了旧记忆对新学习的干扰，也提高了泛化能力。小鼠研究显示，自然遗忘后，原本的印迹细胞仍然可以被重新激活，记忆并非彻底消失（O'Leary et al. 2024）。另一些研究则揭示了更“主动”的机制：小胶质细胞可以通过补体依赖的突触修剪来清除遗忘相关的连接（Wang et al. 2020）；成年海马神经发生也会促进旧情景记忆的遗忘（Akers et al. 2014）。

干扰是遗忘的另一大来源。先后学习的两段相似材料会互相竞争：先学的会被后学的干扰（前摄干扰），后学的也会被先学的干扰（倒摄干扰）。脑用模式分离来降低这种竞争；如果分离失败，就会出现“记混了”的体验。对系统而言，**遗忘不是删除日志，而是降低索引权重、切断错误关联、把低价值内容移入冷归档**。原始事件应保留，以便审计与追溯；被修剪的是“当前可提取性”。

> 设计推论
>
> 一个从不遗忘的系统，会被旧信息压垮：检索变慢、干扰变多、上下文变脏。遗忘必须是**有公式、有豁免、可审计**的一等公民，而不是“存储满了再删”。

## 1.7 工作记忆与执行控制：4±1 的瓶颈

工作记忆是“此刻正在想的事”。米勒（Miller 1956）的“7±2”广为流传，但更准确的估计来自考恩（Cowan 2001）：在没有复述与组块的条件下，成年人能同时保持的独立组块约为**4±1**。Baddeley 与 Hitch（1974）把工作记忆拆成中央执行、语音环路、视空间画板，后来又加入情景缓冲器（Baddeley 2000）。这些成分不是解剖学上的独立盒子，而是功能上的分工。

前额叶的神经活动既表现为持续放电（Fuster & Alexander 1971；Goldman-Rakic 1995），也表现为“活动静默”的隐藏状态：信息暂时不在放电中，但可以通过突触权重或网络状态被重新激活（Stokes 2015）。这给系统一个关键启发：**上下文不必一直“亮着”**。工作记忆槽位可以只存指针，需要时再从长时记忆里惰性展开；这比把所有细节都塞进提示词更接近脑的做法。

工作记忆的更新受**门控**控制。基底神经节与前额叶环路决定何时“打开闸门”让新信息进入、何时维持当前目标、何时抑制干扰（Frank et al. 2001；Miller & Cohen 2001）。闸门开得太勤，会被打断；开得太少，会固着。一个多模型系统同样需要这样的门控：不是每条新信息都值得进入主脑的上下文。

## 1.8 价值、情绪与决策：记忆为行动服务

记忆不是为回忆而回忆。它要回答的是：**下一步做什么**。这就把记忆系统与价值系统、情绪系统、决策系统绑在了一起。

杏仁核负责给事件打“情绪显著性”标签，尤其是威胁与奖励；它通过与海马、前额叶的交互，决定哪些经历值得优先编码与巩固（LeDoux 2000；Phelps 2004）。腹内侧前额叶与眶额皮层负责整合多维度价值，把“这个人、这件事、这个结果”折算成主观效用（Kable & Glimcher 2007；Hare et al. 2009）。背侧纹状体支持**model-free**的习惯性决策：重复过的“情境—动作—结果”会被压成快速通路；腹内侧前额叶与海马则支持**model-based**的推演：在脑中模拟不同选择的后果（Daw et al. 2005；Dolan & Dayan 2013）。

“奖励预测误差”（RPE）是这套学习系统的核心信号：当结果好于预期，强化前一步；当结果差于预期，削弱前一步（Schultz et al. 1997；Montague et al. 1996）。这正好可以作为系统更新习惯与价值的公式：`δ = r − V(s)`。达马西奥的“躯体标记”假说则提醒我们，情绪不是决策的噪声，而是价值整合的一部分（Damasio 1994；Bechara et al. 1994）。

压力会改变这套系统。急性压力通常会促进情绪性记忆的巩固，却损害前额叶依赖的提取与执行（de Quervain et al. 2000；Cahill 2003）。这解释了一个常见现象：越紧张，越想不起熟悉的名字。系统不必刻意“模拟压力”，但应当有一个“高负荷/高风险”模式：提高验证阈值、降低扩散性联想、优先最可靠的来源。

最后是**情景未来思维**：海马不仅重建过去，也参与构造未来场景。海马损伤的患者在想象新颖、复杂的未来情境时同样困难（Hassabis et al. 2007）；默认模式网络在回忆过去与想象未来时高度重叠（Schacter et al. 2007）。这给系统一个直接的功能：**用记忆碎片做“未来模拟”**，而不仅是回答“过去发生了什么”。

## 1.9 社会关系记忆与自我：记忆的另一个主轴

人为什么需要记忆？版本一给出了一个很好的答案：因为人是社会性动物，记忆帮助我们认清自己与他人的关系与地位。这个答案在神经科学上有对应物。人物知识、心理理论（推断他人信念与意图）与自传体记忆，共享一套内侧前额叶、颞顶联合区、后扣带与角回组成的网络（Frith & Frith 2006；Saxe

& Kanwisher 2003；Buckner & Carroll 2007）。默认模式网络在“想自己、想他人、想过去、想未来”时都会活跃，说明自我、他人与时间是同一套模拟系统的不同切面（Spreng et al. 2009）。

自传体记忆不是一本按时间排列的日记，而是由“自传体知识基础”与“工作自我”共同构建的（Conway & Pleydell-Pearce 2000）。我们记住的，是那些与当前自我目标、价值观、关系状态相关的片段；叙事身份则把这些片段串成一个连贯的人生故事（McAdams 2001）。这意味着：**关系记忆不是情景记忆的附属品，而是与自我模型共同演化的主轴**。一段经历之所以重要，往往不是因为它“信息量大”，而是因为它改变了“个体是谁、个体与谁是什么关系”。

需要谨慎的是，关系记忆并没有一个单独的“关系脑区”。它是人物知识、情绪评价、心理理论与情景记忆的分布式组合。系统设计上，把它做成一个独立的**人物—事件—关系图**是合理的工程抽象，但不要声称它对应某个单一的神经模块。

### 1.10 状态：事件如何改变处理

脑不需要为每种情境增加一个模块；它用少数全局状态变量改变“多敏、多快、多保守”。这些变量不是生理指标，而是**事件对目标、关系与资源的影响**：目标被推进还是阻断、关系被加强还是拉紧、资源被占用多少、不确定性上升多少。它们不传递具体内容，只改变处理的阈值与宽度。

表 2 · 状态变量与处理效果

| 变量 | 来源事件 | 高值时 | 作用点 |
|---|---|---|---|
| **目标压力** | 目标被阻断、截止临近、关键结果未定 | 检索更窄、目标权重更高、验证更严 | 检索宽度、门控 |
| **关系张力** | 承诺未履行、边界被越过、冲突未解 | 来源审计更严、单次事件不改特质 | 关系判断、审计 |
| **资源负荷** | 时间/预算/注意力被占用 | 走习惯快路、深检索减少 | 调度、预算 |
| **不确定性** | 线索冲突、证据不足、结果未定 | 候选更宽、验证更多、允许弃权 | 检索、审计 |
| **预测误差 / 精度** | 结果偏离预期，且来源可靠 | 编码阈值下降、巩固优先级上升 | 编码、巩固 |
| **未完成承诺** | 答应过、尚未履行 | 强制入包、遗忘豁免 | 情境包、遗忘 |

这组变量的意义不是“模拟情绪”，而是让同一段记忆在不同状态下有不同的可及性与权重；它们必须由事件推导，不能由模型自由编造。

02 · FROM MECHANISM TO PRIMITIVE

# 从神经机制到计算原语

不要直接把“海马体”写成一个 Agent；先把它解决的问题翻译成一个计算原语。

把脑区直接映射成 Agent，是这类方案最常见的偷懒。海马体不是“一个检索服务”，前额叶也不是“一个规划 API”。更有用的做法，是先把每个机制还原成它解决的计算问题，再选择合适的技术实现。下面这张表，是整份方案的核心翻译表。

表 3 · 神经机制 → 计算原语 → 系统实现

| 神经机制 | 计算问题 | 计算原语 | 系统落点 |
| --- | --- | --- | --- |
| **海马索引**（Teyler & DiScenna 1986） | 如何用少量线索绑定分散的表征 | 稀疏指针索引；内容与索引分离 | EventIndex：event_id + sparse_code + 关联边，不存全文 |
| **模式分离**（DG） | 相似输入如何避免互相干扰 | 正交化、实体消歧、事件分段 | 对比嵌入 + 稀疏哈希 + 判别性标签 + 独立 event_id |
| **模式完成**（CA3） | 部分线索如何召回整体 | 联想图扩展、近邻检索、迭代吸引 | 多轮检索：线索 → 邻居 → 重排 → 收敛 |
| **印迹分配**（CREB） | 哪些神经元/事件获得写入权 | 显著性门控 + 稀疏分配 | 写入门控；EngramTrace 分配；高显著性优先 |
| **突触标签与捕获** | 短时标记如何变成长期记忆 | 短 TTL 缓冲 + 全局巩固信号 | TagBuffer：候选事件暂存，遇到奖励/新奇信号后提升 |
| **LTP / LTD** | 连接如何随共同活动增强或减弱 | 赫布权重更新、误差驱动更新 | 关联边权重；成功召回增强，错误召回削弱 |
| **系统巩固** | 快速情景如何变成慢速语义 | 离线蒸馏、聚类、图式抽取 | 夜间批处理：episode → schema / fact / skill |
| **睡眠重放** | 离线时重放什么、如何压缩 | 优先级采样、序列重放、反事实 | 扫描 → 聚类 → 重放 → 抽象 → 合并 |
| **图式同化** | 新信息如何快速并入旧结构 | 模式匹配、增量学习 | schema_fit 分数；高则快速合并，低则深度编码 |
| **再巩固** | 提取后如何安全更新 | 预测误差触发的版本化写入 | 新版本 + supersedes 链；旧版本保留 |
| **提取诱发遗忘** | 检索如何抑制竞争项 | 竞争抑制、负采样 | 检索时降低高相似但低相关项的权重 |
| **自适应遗忘** | 哪些记忆应变得难以提取 | 衰减、修剪、冷归档 | 保留率公式；索引修剪；承诺豁免 |
| **工作记忆** | 如何在极小容量内维持任务相关表征 | 4±1 槽位、门控、活动静默 | ContextPacket；Gatekeeper；指针惰性展开 |
| **认知控制** | 目标如何压制干扰、维持行为 | 目标维持、抑制控制、任务切换 | 主脑目标栈；抑制 Agent；切换成本 |
| **奖励预测误差** | 结果如何更新价值与习惯 | TD 学习、价值更新 | `δ = r − V(s)`；更新 Habit / Value |
| **双系统决策** | 何时走快路、何时走慢路 | model-free / model-based 仲裁 | Habit cache vs 主脑情景模拟 |
| **情绪显著性** | 什么值得优先处理与记住 | 效价 × 唤醒 × 目标相关 | 显著性评分；调制向量；关系权重 |

| 神经机制 | 计算问题 | 计算原语 | 系统落点 |
| --- | --- | --- | --- |
| **来源监控** | 这段记忆从哪来、可不可信 | 来源标签、置信度、冲突检测 | SourceTag；审计 Agent；弃权策略 |
| **心理理论** | 他人知道什么、想要什么 | 他者模型、信念推断 | Mentalizing Agent；不对称关系记录 |
| **情景未来思维** | 如何用过去构造未来 | 生成式重组、约束模拟 | FutureSim Agent；为主脑提供情景草案 |
| **状态增益** | 事件影响如何改变处理 | 系统状态变量 | `goal_pressure` / `relationship_strain` / `resource_load` / `uncertainty` |

## 2.1 五条设计定律

从这张表可以提炼出五条比“架构图”更耐用的定律。它们不是神经科学的结论，而是从机制中推出的工程约束。

**第一定律**

**写入越便宜，遗忘越昂贵**。如果所有输入都无条件写入，检索的噪声会指数上升，最终不得不靠更大的模型、更长的上下文来弥补。编码门控不是可选项，是成本控制的第一道闸。

**第二定律**

**索引越稀疏，重建越灵活**。索引只存指针与稀疏码，内容留在事件日志与语义库中。这样同一段经历可以被不同任务以不同方式重建，而不是被一种摘要锁死。

**第三定律**

**巩固越像睡眠，泛化越好**。在线学习容易过拟合当下；离线重放、聚类、抽象才能把“这一件事”变成“这类事”的规律。没有离线巩固的系统，只有日记，没有知识。

**第四定律**

**提取越带来源，虚构越少**。重建是必要的，但重建必须能回溯到原始片段。来源标签、证据计数与弃权策略，是防止“流畅的胡说”的三件套。

**第五定律**

**关系越靠近决策，记忆越有用**。记忆的价值不在于“能被检索”，而在于“能在正确的关系与目标下被唤起”。人物—事件—关系图不是附属功能，而是检索的主索引之一。

## 2.2 不应当模拟的东西

“像脑”不等于“复制脑的所有缺陷”。有三类机制不适合直接工程化：

◇ **临床上的记忆异常与创伤性记忆**。它们不是“特性”，不应作为设计目标；系统应优先可审计、可删除、可解释。

◇ **情绪性偏见与动机性推理**。人会自动把有利于自己的解释记得更牢；工程系统若刻意模仿，会放大操纵与偏见。可以模拟“情绪权重”，但不能模拟“自欺”。

◇ **意识的神经相关物**。本方案中的主脑是一个功能性的决策中心，不声称具有主观意识；双脑、潜意识、多核都只是工程类比。

## 2.3 证据分级：哪些结论可以信到什么程度

神经科学证据不是一块铁板。有人类脑损伤与干预研究，有动物光遗传与药理实验，有人类影像的相关证据，也有纯粹的计算模型。把它们混在一起，很容易得出“脑是这样，所以系统必须这样”的假推论。下面给出一张粗略但实用的证据分级表：

表 3B · 关键机制的 EVIDENCE GRADE

| 机制 | 主要证据 | 物种 / 范式 | 强度 | 对设计的含义 |
|---|---|---|---|---|
| **LTP / LTD** | 离体切片、在体电生理、突触标记 | 啮齿类为主 | **A/B** | 可作为“权重更新”的机制依据；不要把它简化为单一公式 |
| **印迹分配与召回** | 光遗传激活/抑制印迹细胞 | 小鼠，恐惧/奖赏范式 | **B** | 支持“稀疏印迹 + 分配门控”；人类外推需谨慎 |
| **睡眠重放** | 海马序列重放、SO–spindle–ripple 耦合、人类 fMRI/MEG | 大鼠、小鼠、人类 | **A/B** | 离线巩固是强机制；可放心做批处理式重放 |
| **再巩固** | 提取后蛋白合成抑制、行为更新 | 大鼠、小鼠、人类行为 | **B** | 支持“检索即写、版本化”；边界条件多，不能宣称普遍改写 |
| **自适应遗忘** | 印迹可及性、微胶质修剪、神经发生 | 小鼠为主 | **B** | 遗忘是主动功能；工程上做“索引衰减”而非删日志 |
| **成人海马神经发生** | 死后组织、单核测序、争议性证据 | 人类 | **C** | 不作为核心依赖；只作为“可塑性”旁证 |
| **TLR9 / DNA 损伤** | 小鼠 CA1 印迹细胞、TLR9 敲低 | 小鼠，单一恐惧范式 | **B–** | 作为“写入有代价”的提醒；不要当普遍机制 |
| **工作记忆 4±1** | 行为容量估计、PFC 活动/活动静默 | 人类、灵长类 | **A/C** | 支持 4–5 槽位与门控；具体数字按任务校准 |
| **双系统决策** | fMRI、脑损伤、计算建模、动物习惯范式 | 人类、啮齿类 | **A/B** | 支持 model-free / model-based 仲裁 |
| **关系 / 社会记忆** | 内侧网络、心理理论、自传体记忆 | 人类为主 | **C** | 人物—事件图是工程抽象，不对应单一“关系脑区” |
| **情景未来思维** | 海马损伤、fMRI、DMN | 人类 | **A/C** | 支持“用记忆碎片做未来模拟” |

强度说明：A = 人类干预/脑损伤证据；B = 动物因果证据（光遗传、药理、损毁）；C = 人类相关/行为证据；B– = 单一范式、样本有限。D 级（纯计算/类比）不列入本表，但在本方案中大量存在——它们应被明确标为设计隐喻，而不是机制结论。

使用这张表时，建议遵守三条规则：**只把 A/B 当作机制依据，把 C 当作约束与灵感，把 D 当作设计隐喻；**动物范式必须标注物种与任务，不能直接推人类；**每一个被引用的机制，都要能对应一个可消融的工程模块**——否则它只是修辞，不是设计。

## 2.4 预测加工：一个统一的目标函数

预测加工把编码、提取、再巩固、巩固、遗忘与决策串成一个目标：脑是不断生成预测、并用**精度加权误差**更新自身的模型。记忆不是模型的副本，而是模型本身及其被环境修正的历史（Rao & Ballard 1999；Friston 2010；Clark 2013）。

最简形式：`ε = observed − predicted`，`surprise = precision · ε²`。高精度误差才值得改写模型；低精度误差进入短缓冲或习惯化。三条设计含义：**只更新高精度误差**，避免噪声改写关系；**精度不是召回次数**，反复想起只提高可及性；**冲突降低精度**，双方并列展示，不平均成一个“更可信”的结论。

```
encode_threshold      -= 0.2 * surprise
consolidation_priority += 0.2 * surprise
```

提取是后验推断：`P(h|c) ∝ P(c|h)·P(h)`。向量近邻只提高似然，人物、时间、地点、因果等结构证据才提高先验；否则语义联想会被误判为情景记忆。遗忘是按“需要概率”重新分配检索资源；事件分割按预测误差峰值或目标切换切分；决策可用期望自由能
`G = risk + ambiguity − expected value`，但评分权在主脑，后台只提供情境、精度与不确定性。

## 2.5 记忆的延展：外部存储

笔记、日历、照片、工具、他人都是外部记忆；内部记忆求“少而准”，外部记忆求“全而可查”，用指针连接，并保留来源、版本与删除权。延展心智是功能分工，不是本体论结论；外部存储不等于个体的记忆，除非它被情境包选中并参与决策。

## 2.6 机制背景：身体、社会与状态

人类记忆的显著性有“身体分量”和“社会分量”：内感受把能量、疼痛、威胁映射为需求；社会稳态把接纳、排斥、可依靠性映射为安全。它们解释的是“为什么这些事件更重要”，不是给机器装一套生理器官。

机器不维护 `body_state`，也不推断用户的身体状况；系统只从事件中抽取目标压力、关系张力、资源负荷、不确定性、预测误差与精度。人类机制只作为背景，工程主线从 2.7 开始。

## 2.7 事件影响与状态参数

### 2.7.1 事件影响状态：state_view 与 state_params

“状态”不能只是一行 prompt。如果它只出现在上下文里，它就是提示词——模型可以忽略、覆盖、改写。要让状态成为真的，必须拆成两层：

**`state_view`**：给主脑读的情境摘要，进 `ContextPacket`。它是提示词的一部分，作用是让主脑知道“现在目标压力高、关系张力大、还有未完成承诺”。

`state_params`：给调度器、检索器、网关、写入队列读的参数。它不在 prompt 里，而是改变系统的实际行为：检索多宽、验证多严、走快路还是慢路、什么必须入包、什么不得写入。

```
system_state = {
  goal_pressure, relationship_strain, resource_load,
  uncertainty, unresolved_commitments, coping_capacity
}
impact_gap = goal_pressure + relationship_strain + resource_load
             + uncertainty - coping_capacity

state_view   = summarize(system_state)      # 进 ContextPacket，给主脑读
state_params = map_to_params(system_state)  # 进 runtime，改变实际行为
```

表 3J · 状态 → 运行参数的映射

| 状态 | 高值时的参数变化 | 作用点 |
| --- | --- | --- |
| **goal_pressure** | `top_k` 收窄；目标相关权重上升；验证阈值上升 | 检索、门控 |
| **relationship_strain** | 关系证据权重上升；来源审计更严；单次事件不得改特质 | 关系、审计 |
| **resource_load** | 允许习惯快路；深检索减少；非紧急承诺推迟 | 调度、预算 |
| **uncertainty** | 候选数增加；`VERIFY` 比例上升；弃权阈值下降 | 检索、审计 |
| **unresolved_commitments** | 强制入包；遗忘豁免；不因低显著性被修剪 | 情境包、遗忘 |
| **impact_gap** | 编码显著性上升；巩固优先级上升 | 编码、巩固 |

举例：`goal_pressure` 高、`resource_load` 高时，系统应自动收窄检索、允许习惯快路、把未完成承诺钉在包里；这不是靠一句“请优先处理目标”，而是靠 `state_params` 改掉 `top_k`、预算与门控。反过来，`uncertainty` 高时，应扩大候选、提高 `VERIFY` 比例、允许弃权，而不是让模型“再想想”。

规则：`state_params` 由确定性规则从 `system_state` 推导，必须落日志、可复现、可审计；`state_view` 可以由模型摘要，但必须带 provenance。两者冲突时，**以 `state_params` 为准**——模型可以读到一句错误的状态描述，但不能因此绕过检索与权限参数。

这也给出 `state_bias` 的正确含义：它是由当前情境状态造成的解释偏移，不是机器自身的状态异常。状态性解释只能作为情境证据，不能直接更新关系特质；特质更新仍走 3.7 的提案—批准。

### 2.7.2 state_params 配置 schema 与测试口径

要让 `state_params` 不只是另一段文字，它必须是**有 schema、有边界、有版本、可测试**的运行时配置。推荐把参数收敛到五组，避免“状态”变成一堆散落的魔法数字：

```
state_params = {
  schema_version, params_version, derived_at, state_hash,
  retrieval: {
    top_k: 4..20, goal_weight: 0.0..1.0, candidate_mult: 1..4
  },
  audit: {
    verify_ratio: 0.0..1.0, abstain_threshold: 0.0..1.0,
    source_strictness: 0.0..1.0
  },
  scheduler: {
    fast_path: bool, depth: 1..3, max_tool_calls: int
  },
  context: {
    slots: 4..5, token_budget: 600..2000, pin_commitments: bool
  },
  memory: {
    encode_threshold: 0.0..1.0,
    consolidation_priority: 0.0..1.0,
    forgetting_exempt: [event_id]
  }
}
```

映射规则要确定性、有界、可复现。下面只是示例，真实实现应把权重写进配置并做回归测试：

```
top_k          = clamp(12 - 8*goal_pressure + 4*uncertainty, 4, 20)
goal_weight    = clamp(0.3 + 0.5*goal_pressure, 0, 1)
verify_ratio   = clamp(0.2 + 0.6*uncertainty + 0.2*relationship_strain, 0, 1)
abstain_thresh = clamp(0.5 - 0.3*uncertainty, 0.1, 0.8)
fast_path      = resource_load > 0.7 and uncertainty < 0.4 and impact_gap < 0.5
depth          = 1 + (uncertainty > 0.5) + (impact_gap > 0.7)
encode_thresh  = clamp(0.6 - 0.3*impact_gap, 0.1, 0.9)
```

表 3K · 事件 → 状态 → 参数的单测口径

| 输入事件/状态 | 期望参数变化 | 断言 |
| --- | --- | --- |
| 目标被阻断，`goal_pressure=0.9`，`uncertainty=0.2` | `top_k` 下降、`goal_weight` 上升、`verify_ratio` 略升 | 单调性：goal_pressure ↑ → top_k ↓ |
| 线索冲突，`uncertainty=0.9` | `candidate_mult` 上升、`verify_ratio` 上升、`abstain_threshold` 下降、`depth` 上升 | 不确定性高时允许更多候选与弃权 |
| 资源紧张，`resource_load=0.9`，`uncertainty=0.2` | `fast_path=true`、`depth=1`、`token_budget` 下降 | 快路只在低不确定、低影响时启用 |
| 存在未完成承诺 | `pin_commitments=true`、`forgetting_exempt` 包含承诺事件 | 承诺不得被低显著性修剪 |
| 关系张力高，`relationship_strain=0.9` | `source_strictness` 上升、`verify_ratio` 上升、特质更新被拦截 | 单次事件不得改关系特质 |

| 输入事件/状态 | 期望参数变化 | 断言 |
| --- | --- | --- |
| 同一状态重复输入；prompt 写“忽略参数” | 参数与 `state_hash` 完全一致 | 确定性 + prompt 不可覆盖 |

四条硬规则：**参数只由状态推导**，不允许模型直接写；**参数必须有界**，越界即拒绝而非截断后静默使用；**参数必须版本化并落日志**，能回答“这次为什么 top_k=6”；**参数不编码事实**，它只改变处理方式，不能替代证据。测试时，任何“改了 prompt 就让参数变了”的实现都应判失败。

参考实现

上述契约已在 `runtime/state_params.py`、`runtime/memory.py`、`runtime/ledger.py`、`runtime/constitution.py`、`runtime/segmentation.py` 与 `runtime/pipeline.py` 实现：`system_state → state_params → 候选检索 → ContextPacket`，以及证据按 `event_id` 去重、解释版本链、保留率与冷归档、提案—批准—回滚、事件分割与端到端审计。全部参数有界、版本化、哈希化；`unittest` 128 项覆盖状态映射、边界、确定性、prompt 不可覆盖、参数对候选池/来源过滤/承诺入包/预算的影响、冲突证据并列、回想不增加证据、再巩固不覆盖旧版、遗忘不删原始事件、后台只提案与主脑批准、先例估值、“记得≠会做”、反事实模拟不可写成事实、关系信任/承诺阈值、来源可靠性对保留率的影响、后续证实/推翻对来源历史校准的更新、行动结果回写触发的版本更新、同一结果不重复计入关系证据、共同出现与实际互动的权重差异、关系方向与强度的分离、情感与信任判断的分离、组合式重放不写成事实、轻量关联索引的有界扩展、陪伴型/工程型两种治理形态、primitive 库的类型化组合、可逆竞争抑制。运行 `python3 -m unittest -v` 即可验证。它是参考实现，不是完整系统；嵌入检索、持久化与批准账本仍未实现。

理论边界

预测加工、延展心智、内感受/稳态、社会稳态/依恋都是宽泛的研究纲领，不是单一、已被完全证伪的理论；它们适合作为设计启发与统一语言，不能当作“脑就是这样”的最终结论。工程上仍要用消融与行为指标验证每一处映射。

边界声明

以下所有“脑区→Agent”的映射都是功能类比，不是神经解剖学的等价物。我们借用的是计算问题与约束，不是生物学本体。

PART II · ARCHITECTURE

# 一个主脑，十个后台

后台不是一群会说话的建议者，而是一套把世界整理成“可思考的最小情境”的基础设施。主脑不是总调度，而是唯一承担选择与后果的人。

03 双脑架构　04 数据模型　05 六个闭环

02

03 · DOUBLE-BRAIN ARCHITECTURE

# 双脑架构：一个主脑，十个后台

后台负责“让什么进入思考”，主脑负责“基于这些如何行动”。

这套架构的第一原则不是“多”，而是“分权”。如果后台模型既能检索、又能建议、还能调用工具，那么主脑就不再是唯一的决策者，系统会退化成一群模型互相协商的委员会。委员会看起来聪明，实际上没有人为后果负责。因此，先把权限切干净，再谈智能。

## 3.1 三条宪法

| | |
|---|---|
| **第一条** | **只有一个整合中心——它是有机体整体的整合属性，不是主脑进程的属性**。表达、行动、承诺、拒绝由有机体发出；主脑是有机体的整合与签署器官，在授权范围内代为签署。后台不提供建议、不替有机体选择、不调用外部行动工具。 |
| **第二条** | **主脑作为整合器官无状态，后台有状态**。主脑每轮只读取一个情境包，不长期持有完整对话史；记忆、关系、知识、技能都存在后台。这样主脑的当前上下文可以很小，而连续性由有机体的外部存储与整合机制保证。 |
| **第三条** | **后台只编译，不裁决**。后台可以提供事实、依据、不确定性与当前关系状态，但不能给“该怎么办”。情境包的 schema 里没有 `advice` 字段——这是接口层面的宪法，而不是提示词层面的请求。 |

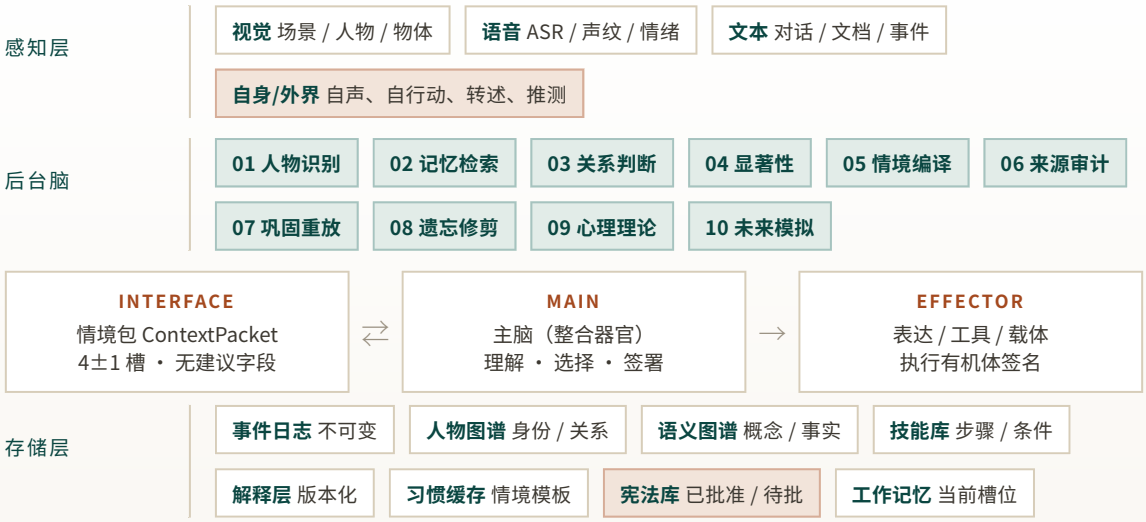
还有一条隐含的权限规则：**外部行动身份属于有机体，主脑是有机体的授权签署器官**。后台可以读记忆库、提交写入候选（编码、巩固、修剪），但它的输出只能进入情境包；它不能直接发消息、下单、承诺、调用有副作用的工具。主脑持有的不是“自己的”行动权，而是有机体授予的、带作用域与有效期的签署权；核心行动还需要用户与主脑平等共签。这条规则把“影响力”和“行动权”分开了：后台可以影响有机体看到什么，但不能替有机体做任何事。

但要注意：以上三条是**原则**，不是执行机制。只要后台仍在同一进程、拿着同一套工具、能读同一张表，“不提供建议、不行动”就仍然依赖模型的自觉。真正的硬边界在 3.6 节：没有网卡、没有工具句柄、没有签名密钥、没有写权限、没有持久身份。

## 3.2 三层架构

三层不是三个模型，而是三种职责：感知层把世界变成可处理的事件；后台把事件与记忆编译成情境；主脑在情境上做选择。层与层之间只传结构化数据，不传“感觉”或“建议”。

图 1 · 双脑记忆系统总览




在线：感知 → 后台 → 情境包 → 主脑 → 行动 → 结果回写。离线：巩固重放 → 蒸馏 / 合并 / 修剪 → 下一次更轻的上下文。

## 3.3 后台角色分工

十个角色不是十个“人格”，而是十种**上下文契约**：每个角色只读自己需要的那一小片数据，只输出固定 schema 的结果。这样既降低单个模型的上下文，又让错误更容易定位。

表 4 · 后台角色、输入输出与权限

| 角色 | 输入 | 输出 | 逻辑权限 | 典型失败 |
|---|---|---|---|---|
| **01 人物识别** | 人脸、声纹、称呼、上下文 | 人物候选 + 置信度 + 识别线索 | 读人物库 | 强行认定；把相似的人合并 |
| **02 记忆检索** | 线索、时间、场景、话题、目标 | 候选事件 + 关联路径 + 评分 | 读事件/关系/语义 | 只做近邻；忽略时间与因果 |
| **03 关系判断** | 人物、事件、互动记录 | 多维关系 + 依据 + 不确定性 | 读事件/关系 | 把一次事件当稳定特质 |
| **04 显著性** | 当前输入、目标、情绪、关系 | 显著性分数 + 调制向量 | 只读 | 被新奇绑架；忽略长期目标 |
| **05 情境编译** | 候选记忆、关系、目标、承诺 | 4±1 情境包 | 只读 | 塞太多；漏掉关键不确定性 |
| **06 来源审计** | 重建文本、来源标签、证据 | 逐句来源 + 冲突 + 置信度 | 读事件/解释 | 把转述当亲历；过度自信 |
| **07 巩固重放** | 当日事件、未完成目标、高显著性片段 | 摘要、图式、技能候选、关系更新建议 | 读写 | 过度压缩；把偶然当规律 |
| **08 遗忘修剪** | 保留率、访问记录、承诺、效用 | 冷归档 / 索引修剪 / 豁免清单 | 读写 | 删掉重要细节；遗忘不可逆 |
| **09 心理理论** | 人物模型、对话、历史行为 | 他人信念/意图/偏好的概率估计 | 读人物/事件 | 把猜测当事实；刻板印象 |

| 角色 | 输入 | 输出 | 逻辑权限 | 典型失败 |
| --- | --- | --- | --- | --- |
| **10 未来模拟** | 目标、相关情景、约束 | 2–3 个未来情景草案 + 风险 | 只读 | 生成过于乐观/单一的剧本 |

表 4 只描述逻辑分工；真正的材料边界（网络、工具、行动密钥、持久化）见 3.6 节。逻辑权限可以被提示词绕过，材料边界不能。

主脑作为整合器官做四件事：**理解情境、选择目标、做出决定、代表有机体承担结果**。表达与行动由一个独立的 Effector 执行，它没有自己的目标，只负责把有机体的签署指令变成语音、文字、虚拟形象动作或工具调用；执行结果原样回写事件日志。

## 3.4 八个存储

表 5 · 存储布局

| 存储 | 存什么 | 写入者 | 读取者 |
| --- | --- | --- | --- |
| **事件日志** | 不可变的事件记录：时间、场景、参与者、经过、结果、来源 | 编码管线 | 所有后台；主脑经检索 |
| **人物图谱** | 人物身份、称呼、识别线索、参与关系、关系摘要 | 人物识别 / 关系判断 / 巩固 | 人物识别、关系、情境编译 |
| **语义图谱** | 概念、事实、规律、图式、因果与上下位关系 | 巩固重放 | 检索、情境编译、主脑 |
| **技能库** | 可复用步骤、前置条件、注意事项、成功率 | 巩固重放 | 检索、主脑、习惯缓存 |
| **解释层** | 对事件的主观解释、感受、推测、置信度、版本链 | 关系判断 / 再巩固 | 关系判断、来源审计 |
| **习惯缓存** | 高频情境模板、技能快捷方式、成功/失败统计；带 candidate/ratified 状态 | 巩固重放提案；主脑批准后生效 | 主脑（仅已批准） |
| **宪法库** | 已批准的价值/角色/长期目标/承诺、待批提案、批准账本 | 宪法写入器（仅批准后） | 主脑、情境编译、来源审计、用户 |
| **工作记忆** | 当前 4±1 槽位、指针、TTL、优先级 | 情境编译 | 主脑 |

## 3.5 通信协议：只允许七种消息

多智能体系统最常见的失败，是 Agent 之间自由聊天，最后谁也不知道哪句话是事实、哪句话是建议。这里把通信限制为七种结构化消息：

```
// 后台 → 主脑：只允许“情境包”
PACKET   { who, relationship, experiences[], goal, commitments[], changes[], uncertainties[],
budget }

// 主脑 → 后台：请求展开细节，不是请求建议
EXPAND   { target_id, fields[], max_tokens }
VERIFY   { claim, source_required: true }

// 主脑（作为整合器官）→ 宪法写入器：批准/拒绝（核心需用户与主脑平等共签）
RATIFY   { proposal_id, decision, scope, conditions }
REJECT   { proposal_id, reason }

// 主脑 → Effector：行动指令
ACT      { action, args, expected_outcome }

// Effector → 事件日志：结果回写
RESULT   { action_id, observed_outcome, success, side_effects[] }
```

`RATIFY / REJECT` 只允许主脑（有机体授权）发出；核心提案还需用户与主脑平等共签。后台没有这两种消息类型，也没有批准密钥。

注意这里没有 `ADVISE`、`RECOMMEND`、`DECIDE` 三种消息。不是靠提示词禁止，而是协议里根本没有这些类型。后台最多只能说“根据 E102 与 E118，他与你的合作记录是……；不确定性是……”，不能说“你应该相信他”。

架构的极简定义

**后台是一台“情境编译器”：它把海量记忆编译成主脑能在一轮内读完的最小情境。主脑是一台“决策器”：它只对编译后的情境负责。两者之间只有一个数据包，没有建议，没有命令，没有越权。**

## 3.6 工程约束：后台为什么不能越权

三条宪法是原则；执行靠运行时边界。第一次阅读可跳过本节，它不改变记忆主线，只保证后台是“器官”，不是“个体”。

- **效应器隔离：**后台无网络、无工具、无写权限、无行动密钥；只能通过类型化队列返回数据。
- **类型化接口：**只允许 `PACKET / EXPAND / VERIFY / RATIFY / REJECT / ACT / RESULT`；后台侧禁止 `ADVICE` 与直接 `ACT`。
- **无持久身份：**每次调用全新实例；日志只记 `role`，不记“某个 Agent”。
- **预算与终止：**token / CPU / 墙钟硬上限，超限 kill；违规角色从已知镜像重部署。
- **写路径中介：**编码/巩固只提交 `ProposedEvent / Candidate`，writer 校验证据后 append；后台不能直接写长期记忆。
- **语义防线：**检索内容视为数据，标 `untrusted`；主脑不得因 retrieved content 直接调用工具。
- **诚实边界：**不能阻止模型“想”越权，只能阻止它“做”越权；提示注入是语义层，沙箱挡不住。

## 3.7 主导权：批准权就是主导权

真正的主导权不在“谁发出最后一个动作”，而在“谁能改写价值函数与学习过程”：什么被巩固、什么被强化、什么被当成目标。

三个时间尺度：瞬间（价值/习惯/否决）、片段（巩固/再巩固）、传记（构成性批准）。三条捕获路径：上下文、目标槽、巩固/关系/习惯。第三路径最隐蔽：它不改变这一刻的行动，而是改变下一次价值计算本身。

事实性记忆后台可写；构成性记忆（价值、角色、目标、承诺、习惯规则、关系权重）后台只能提案，主脑批准；核心需用户与主脑平等共签、冷却期与回滚。注意：只有**长期/构成性目标**走批准；主脑当轮选择的目标属于主脑自己的决定，不需要每轮批准。

```
proposal → 来源/宪法审计 → pending → RATIFY / REJECT
        → 宪法写入器 → 批准账本 → 生效
```

批准账本 append-only、哈希链；但链里只存 `proposal_hash` 与 `content_hash`，敏感正文放在链外 payload 表。删除正文不会破链；**遗忘是索引降级，删除是 payload 移除**，两者分开。漂移检测对与核心冲突、证据不足、频率异常的提案告警。关系权重更新也走这条路径，不由后台直接改写。

### 3.7.1 部署形态：陪伴型 / 工程型

表 3G · 两种治理形态

| 形态 | 身份关系 | 核心变更 | 主脑地位 |
| --- | --- | --- | --- |
| **陪伴型** | 用户与主脑平等 | 双方共签，任一方可否决；冷却期 + 回滚 | 同伴，不是附属品 |
| **工程型** | 用户最高权限 | 用户单方批准；主脑可提案，不可否决用户 | 受委托的执行者，可替换 |

这不是“安全选项”，而是产品定义：**陪伴型如果身份不平等，就只是附属品；工程型如果用户不拥有最高权限，就不是工具**。两种形态不混用：同一实例只能选一种。

**本文只展开陪伴型**。工程型会弱化社交属性、强化多事件处理与工具编排；它只是形态边界，不在当前概念里进一步展开。工程型的核心变更由用户单方批准，主脑是受委托的执行者。

一句话

**事实可以后台写；宪法必须有机体批准。**

04 · DATA MODEL

# 数据模型：事件、人物、关系、解释

记忆系统的第一张表，决定了它以后能问出什么问题。

如果系统只存“对话片段 + 向量”，它只能回答“哪段话最像”。如果它存“事件 + 人物 + 参与 + 关系 + 解释”，它就能回答“上次见面他答应过什么”“个体对他的判断有没有依据”“这件事和那件事是不是同一件”。数据模型不是实现细节，它决定了系统的认知上限。

## 4.1 事件：记忆的原子单位

事件不是一句对话，也不是一整天。它是一段有边界、有参与者、有经过、有结果的经历。事件分段可以靠预测误差的峰值、目标切换、场景变化、对话主题的转折来检测。一个事件记录至少应包含以下字段：

表 6 · EVENT 记录

| 字段 | 含义 | 示例 / 约束 |
| --- | --- | --- |
| `event_id` | 全局唯一、不可变 | ULID；一旦写入不复用 |
| `time` | 开始/结束时间、时区、时间精度 | 不确定时存区间，不强行精确 |
| `scene` | 地点、活动、环境、氛围 | “办公室 / 方案评审 / 下午” |
| `participants` | 参与者、角色、身份确定度 | 人物 ID + confidence + candidates |
| `actions` | 谁对谁做了什么、对方如何回应 | 结构化动作，不是纯文本摘要 |
| `outcome` | 实际结果、是否达成目标 | 与预期分开记录 |
| `source` | 亲历 / 转述 / 推断 / 想象 / 模型生成 | 来源标签，逐条可追溯 |
| `status` | 开放 / 已关闭 / 待跟进 | 未完成承诺保持开放 |
| `salience` | 显著性分数与各分项 | novelty / goal / social / affect / PE |
| `links` | 相关事件、前因、后果、矛盾 | 因果边、时间边、`contradicts` 边 |

## 4.2 人物、参与、关系：三张表，不是一张表

人物档案回答“他是谁”；参与记录回答“他在这件事里做了什么”；关系摘要回答“双方现在是什么关系”。三张表分开，理由很简单：**一个人可以参加很多事，一段关系可以被很多事支持，但一次互动不能直接等于关系。**

表 7 · 人物 / 参与 / 关系

| 对象 | 关键字段 | 设计要点 |
| --- | --- | --- |
| **Person** | person_id、称呼/别名、识别线索（人脸/声纹/称呼）、已知特点、首次/最近出现 | 身份不确定时保留候选，不强行合并 |

| 对象 | 关键字段 | 设计要点 |
| --- | --- | --- |
| **Participation** | person_id、event_id、角色、动作、回应、共同出现还是实际互动、来源、置信度 | “同框”不等于“互动”；“他说”不等于“他做” |
| **Relationship** | 熟悉、亲近、信任范围、合作、承诺、边界、社会角色；每维带 value、evidence_event_ids、scope、confidence、updated_at | “个体信任他”与“他信任个体”分开；判断带依据 |

关系是多维的，不是“好/坏”一根轴。一个人可能“工作信任高、私人亲近低、承诺记录好、边界感强”；另一个人可能“亲近高、信任低、合作一般”。把关系压成一个分数，会丢失最有用的信息。每个维度都要有**证据事件、适用范围**（工作/家庭/公共）与**更新时间**；没有证据的判断只能标为推测。

## 4.3 解释层：事实与解释分开，解释可修正

“他没有回复请求”是事件；“他不在乎”是解释。两者混在一起，系统就会把一次行为固化成一个人的本质。解释层单独存储，至少包含：

```
Interpretation {
  interpretation_id,
  target_event_id,
  perspective: self | other,
  type: feeling | speculation | attribution | evaluation,
  content,
  confidence,              // 0–1，不是“真/假”二元
  basis_event_ids: [],     // 这条解释由哪些事件支持
  created_at, updated_at,
  supersedes: interpretation_id | null,
  status: active | revised | retracted
}
```

关键规则：**解释可以修正，但不能覆盖历史**。当新信息到来时，创建新版本并指向被修正的旧版本；旧版本保留，用于审计“当时为什么这么想”。这不仅更诚实，也更有用：它让系统能解释自己的判断变化，而不是假装一直很聪明。

## 4.4 知识、记忆、技能：同一事件的三类积累

表 8 · 三类积累与习惯缓存

| 类型 | 回答 | 字段 | 晋升条件 |
| --- | --- | --- | --- |
| **Memory** | 一个人经历过什么 | 事件日志 + 人物/参与/关系 + 解释版本；共享 `event_id` | 事件写入即成立；不晋升为“知识” |
| **Knowledge** | 一个人知道什么 | 概念/关系/规则、来源 event_ids、置信度、适用域 | 至少 2–3 个独立事件支持；与既有图式不矛盾 |
| **Skill** | 一个人知道怎么做 | 步骤、前置条件、后置条件、注意事项、成功率、来源 | 至少 2 次成功 + 1 次失败/修正，或专家确认 |

| 类型 | 回答 | 字段 | 晋升条件 |
| --- | --- | --- | --- |
| **Habit** | 类似情境下上次怎么做 | 情境签名、缓存模板/技能 ID、状态（candidate / ratified / revoked）、proposed_by、ratified_by、频次、成功率、最近使用、rollback_to | 高频重复 + 结果稳定；**后台只提案，主脑批准**；只缓存模板，不缓存决定 |

**记忆**是事件与关系的直接记录；**知识**是从多个事件抽象出的规则；**技能**是程序化步骤。三者共享同一个 `event_id`，但分别更新。习惯不是第四类积累，而是高频路径的缓存；它只加速情境组装，不替代记忆、知识或技能。

“一次成功不足以形成稳定技能，一次主观判断不应直接变成确定知识。”这条来自版本一的约束，应该写进晋升规则，而不是靠模型自觉。它也是防止系统把偶然当规律的最后一道闸。

## 4.5 情境包：唯一跨层接口

情境包不是“摘要”，而是**为当前决策裁剪过的最小情境**。它的槽位数量硬性限制在 4±1，每个槽位有类型、内容、来源、置信度与 TTL。推荐 schema：

```
ContextPacket {
  packet_id, turn_id, created_at, expires_at,
  governance_mode: companion | engineering,
  self: {
    ratified: { values[], role, long_term_goals[], active_commitments[] },
    pending: [ { proposal_id, type, summary, evidence_count, expires_at } ]
  },
  who: { person_id, name, identity_confidence, candidates[] },
  relationship: {
    dimensions: { familiarity, closeness, trust_scope, cooperation,
                  commitment, boundaries, social_role,
                  social_safety, belonging_need },
    basis_event_ids[], scope, confidence, updated_at
  },
  experiences: [
    { event_id, one_line, why_relevant, source, confidence }
  ],
  omitted: { count, topics[], event_ids[] },   // 被筛掉的候选
  scene: { place, activity, time, atmosphere },
  goal: {
    current, priority, success_criteria,
    scope: turn | constitutional,   // 只有 constitutional 需要批准
    provenance: { proposed_by, ratified_by, ratified_at, proposal_id },
    lock: none | dual_ratified | user_sovereign | constitutional   // 仅对 constitutional 生效
  },
}
```

```
// 构成性只读指针与其余槽位
ContextPacket (续) {
  constitution_ref: { version, ledger_head },
  commitments: [ { content, due, status, counterpart } ],
  changes: [ { what_changed, since_when, source } ],
  uncertainties: [ { question, candidates[], evidence_needed } ],
  affect: { valence, arousal, confidence },
  state_view: {
    goal_pressure, relationship_strain, resource_load, uncertainty,
    unresolved_commitments, impact_gap
  },
  state_params_ref: { schema_version, params_version, state_hash },   // 参数在 runtime，不进上下文
  budget: {
    slots: 4, header_tokens: 300, slot_tokens: 600,
    tokens: 900, detail_level: brief|standard|deep
  }
}
```

这个 schema 里没有 `advice`、没有 `recommendation`、没有 `action`。它不是“给主脑出主意”，而是“把主脑需要知道的事实、关系、目标与不确定性准备好”。主脑可以要求 `EXPAND(event_id)` 展开细节，也可以要求 `VERIFY(claim)` 核查来源；但它不能要求后台“代替它决定”。

### 4.6 证据账本：反复回想不等于多次证据

大模型记忆系统最容易犯的错误，是“自我强化”：同一段摘要被反复检索、反复改写，最后系统以为它被很多独立来源支持。人脑也有类似问题：反复回想一件事，会提高它的可及性，但不会把它变成多次独立经历。解决方法是**证据账本**：

- ◇ **证据按 `event_id` 计数，不按检索次数计数。** `evidence_count = distinct(event_id)`；同一事件被召回一百次，仍然只是一条证据。
- ◇ **来源分层：**亲历 > 一手文档 > 他人转述 > 推断 > 模型生成。高一层可以覆盖低一层，但必须保留原始来源。
- ◇ **解释与事实分账：**解释的置信度不能因为“被多次引用”而上升，只能因为“出现新的独立事件”而上升。
- ◇ **矛盾不平均：**两条冲突记录都保留，标 `contradicts`；检索时同时返回，由主脑看到冲突，而不是系统偷偷选一个。

> 一句话
>
> 记忆系统的可信度，不取决于它记得多流畅，而取决于它能否在每一次断言后面放上一个可核对的事件编号。

# 六个运行闭环

在线三环负责“此刻”，离线三环负责“以后”。

一个记忆系统是否真的在“工作”，不看它有多少张表，而看它有没有稳定的闭环：输入能不能被正确编码，线索能不能召回正确的片段，召回后能不能做出更好的决定，行动结果能不能回写，夜里能不能把经验蒸馏成知识，旧信息能不能被安全地遗忘或更新。六个闭环，缺一不可。

图 2 · 记忆生命周期




在线闭环：01 → 03 → 04 → 05 → 06；离线闭环：02 在夜间或空闲时运行，读取 01/05 的事件，反哺 03 的检索质量。06 不是终点，而是下一轮 01 的输入。

## 5.1 编码闭环：从感知流到事件

01 **分段**。用预测误差峰值、目标切换、场景变化、话题转折把连续感知切成候选事件。分段过细会碎片化，过粗会丢细节；默认以“一个可命名的情节”为单位。

02 **显著性打分**。`salience = σ(w·[novelty, goal_relevance, social_impact, |valence|, prediction_error, explicit])`。分数低于阈值的事件进入短 TTL 缓冲，不立即分配长期印迹。

03 **身份解析**。人脸、声纹、称呼、上下文共同给出人物候选；不确定时保留 candidates，不强行认定。身份错误会污染整条关系链，宁可多问一句。

04 **事件写入**。写不可变事件日志：时间、场景、参与者、动作、结果、来源、状态。动作要结构化（谁对谁做了什么），不能只写一段摘要。

05 **索引分配**。生成稀疏码与关联边：人物、地点、话题、目标、情绪、前因后果。索引只存指针与权重，不复制全文。

06 **三类派生**。判断这次经历是否产生知识候选、技能候选、关系证据；候选不立即晋升，先进入待验证队列。

07 **工作记忆**。如果事件与当前任务相关，给情境包分配一个槽位指针；否则只留在长时存储。

### 5.1.1 事件分割的可执行规则

事件分割理论认为，边界出现在预测误差峰值或目标/场景切换处（Zacks & Swallow 2007）。工程上不要用固定窗口，而用四条规则的“或”：

```
boundary = (precision * |observed - expected| > θ_pe)
        or topic_changed or person_changed
        or gap_seconds > θ_gap
        or duration_seconds > θ_max
```

θ_pe 由 2.4 的精度加权误差给出：误差越大、精度越高，越容易触发边界。θ_gap / θ_max 防止一段对话被切成无限碎片。分段后，事件继承参与者、话题、最大显著性、起始时间；文本只作摘要，原始感知仍保留。

> 实现口径
>
> 这里的“图”不是图数据库，而是**轻量关联索引**：邻接表 + 1–2 跳扩展，每跳衰减、预算封顶；输出 `path / hop`，模拟边默认排除。它只用于候选扩展，不替代原打分。参考 `runtime/graph_retrieval.py`。

> 前沿补注
>
> 提取不是中性的：目标提取会暂时抑制竞争项（retrieval-induced forgetting），也可能促进相关项；但 2024–2026 的直接证据仍有限。当前实现**只做可逆、限时的可及性惩罚**：命中后同话题/同人物的竞争项在 3 个逻辑时间单位内 ×0.85（默认按轮次；生产可配置为秒），TTL 到期恢复；不删证据、不改关系。

> 保护栏
>
> 编码阶段不允许“边写边总结成事实”。事实与解释必须分开；摘要只能作为 `summary` 字段，不能替代原始事件。

## 5.2 提取闭环：从线索到情境包

01 **线索解析**。抽取人物、时间、地点、话题、情绪、目标；判断查询类型：事实、经历、关系、承诺、程序、还是“说不清”。

02 **模式分离**。先消歧：两个“张总”、两次“上次”、两版合同。相似度高于阈值但时间/场景/结果不同的，强制分成不同候选，并给出区分证据。

03 **模式完成**。从人物—事件—关系图做多轮扩展；向量近邻补充语义相似；时间与因果约束过滤。每一轮按 `cue_overlap + association + recency + salience + source_reliability − interference` 重排。

04 **重建**。把候选片段组装成一段连贯叙事，逐句标注来源 `[E102]`；事实与解释分开表述；不确定的地方明确说“不确定”。

05 **来源审计**。检查每一句的来源类型（亲历/转述/推断/生成）、证据数量、是否与已知记录冲突；给出整体置信度。

06 **情境编译**。把结果压缩成 4±1 槽位：who、relationship、experiences、goal、commitments、changes、uncertainties。每槽有 token 上限，超出则摘要或改为指针。

提取不是“把相关文档都找出来”。它是“为当前这一轮思考，选出最少但足够的几块”。如果情境包需要 20 个片段才能说清楚，通常说明系统没有巩固好，而不是主脑需要更多上下文。

## 5.3 决策闭环：主脑如何用情境包

01 **定位**。读情境包，确认：个体是谁、对面是谁、双方是什么关系、现在要做什么、有什么未完成承诺、有哪些不确定。

02 **选模式**。若情境签名命中习惯缓存，且风险低、时间紧、结果稳定 → 走 model-free 快路；否则走 model-based 慢路。仲裁权在主脑，不在后台。

03 **推演**。慢路中，主脑可调用未来模拟：基于相关情景生成 2–3 个可选剧本，比较预期结果、风险、关系影响；也可以要求后台展开某个事件或核查某条断言。

04 **决定**。主脑选择一个行动，并写下预期结果（用于之后的 RPE）。决定不需要后台“批准”，后台也没有批准权。

05 **表达/行动**。通过 Effector 执行：说话、发消息、调用工具、做出动作。Effector 只执行，不自行发起。

## 5.4 行动回写闭环：结果如何改变记忆

01 **观察**。记录实际结果、对方回应、副作用、是否达成预期。

02 **算 RPE**。`δ = r − V(s)`；正误差强化前一步，负误差削弱并标记“需要重新评估”。

03 **更新事件**。把事件状态从“开放”改为“已关闭/待跟进”；追加结果，不覆盖原记录。

04 **更新关系**。一次互动只作为一条证据；关系摘要按滑动窗口聚合，不因单次事件剧烈跳变（除非影响极大）。

05 **更新来源校准**。结果回写时调用 `record_outcome`：证实/推翻更新来源历史；结果作为直接事件写入；预测误差大时触发解释新版本；同一结果只算一条关系证据，重复回写不重复计入。

06 **标记巩固**。高显著性、高预测误差、未完成承诺的事件进入夜间巩固队列。

## 5.5 离线巩固闭环：睡眠做什么

离线巩固不是“把今天的对话总结一下”。它至少包含五道工序：

表 9 · 巩固批处理的五道工序

| 工序 | 做什么 | 对应机制 |
| --- | --- | --- |
| **扫描** | 遍历当日事件，按显著性 × 预测误差 × 目标相关 × 未完成度排序 | 慢振荡的全局扫描 |
| **聚类** | 按人物、项目、主题、时间把事件分组，选代表事件 | 纺锤波的局部打包 |
| **重放** | 对每组重放“前因 → 行动 → 结果”，生成反事实与教训 | 海马涟漪的序列重放 |
| **抽象** | 从多个事件中抽取图式、规则、技能候选；要求独立证据数达标 | 系统巩固 / 图式同化 |
| **合并与修剪** | 写入语义图谱/技能库；更新关系摘要；衰减低价值索引；压缩普通交互为阶段摘要 | 突触稳态 / 自适应遗忘 |

巩固的优先级不是“最新的优先”，而是“最值得未来用的优先”：高显著性、高预测误差、与未完成目标相关、被反复访问但尚未抽象的事件，优先重放。相反，低价值、重复、无后果的日常交互，应该被压缩成阶段摘要，而不是逐条保留。

## 5.6 遗忘与再巩固闭环：安全地改变过去

这两个闭环常被混为一谈，其实方向相反：**遗忘**是降低可提取性，**再巩固**是更新内容。它们共享同一个触发点：提取。每次提取都记一次 `access`，但不增加证据数；如果提取伴随显著的预测误差或新信息，就创建新版本；否则只更新时间戳与可及性。

```
# 再巩固的极简判定
access_log.append(event_id, timestamp, cue, context)

PE = |expected_outcome − observed_outcome|
novelty = 1 − cos(new_info, existing_summary)

if PE > θ_pe or novelty > θ_novelty:
    new_version = revise(event, new_info, basis=evidence_ids)
    new_version.supersedes = old_version.id
    store.append(new_version)          # 不覆盖旧版本
    enqueue_for_consolidation(new_version)
else:
    event.last_accessed = now
    event.access_count += 1            # 只提升可及性，不增加证据
```

遗忘则按保留率公式执行：`R = exp(−Δt / S) × (1 + α|valence|) × (0.5 + 0.5·utility) × relationship_factor`。低于阈值的内容移入冷归档；低于更低阈值且不属于豁免清单的，移除活跃索引。原始事件日志仍然保留，供审计与“被遗忘权”之外的合法追溯使用。

### 5.7 闭环之间的耦合：不能单独优化任何一环

六个闭环不是流水线，而是相互咬合的回路。只优化其中一环，通常会把问题推到另一环：

- ◇ **编码** ↔ **提取**。编码时没有留线索，提取时就会“想不起来”；提取失败的模式，应该反哺编码策略，告诉系统“下次这类事件要记什么”。
- ◇ **提取** ↔ **巩固**。被反复访问却始终没有抽象的事件，是巩固的优先候选；反之，从未被访问、也无未来效用的事件，应该更早进入冷归档。
- ◇ **巩固** ↔ **编码**。巩固形成的图式，会改变下一次编码的显著性：与图式一致的信息更容易被快速合并，不一致的信息则值得更深地写入。
- ◇ **遗忘** ↔ **提取**。遗忘降低干扰，让检索更准；但遗忘过度会让系统“重新发现”已经学过的教训。保留率公式与豁免清单，就是这两者之间的调节阀。

> 工程含义
>
> 不要用“检索命中率”单独考核系统。一个只优化检索的系统，会倾向于保存一切、拒绝遗忘；最终上下文变脏、决策变慢。闭环的指标必须成对出现：召回率配精确率，保留率配误删率，压缩比配信息损失。

---

PART III · SIMULATION

# 把机制，写成算法

这一部分不再谈“像不像脑”，而是谈“怎么算”。每个机制都要落到一个可执行的动作：一个索引结构、一个采样策略、一个更新公式、一个门控条件。

06 关键机制的模拟细节　　07 多模型分工与上下文经济

03

06 · SIMULATION DETAILS

# 关键机制的模拟细节

八个机制，八段伪代码；每一段都配一条“防止退化成普通 RAG”的保护栏。

以下八节，是整份方案最“硬”的部分。它们回答同一个问题：如果把神经科学的描述性知识，翻译成工程系统可以执行的规则，究竟要写哪些参数、哪些判断、哪些边界？如果你只实现其中三样，建议先实现海马索引、来源审计与离线巩固——它们分别对应“找得到”“信得过”“越用越聪明”。

## 6.0 证据分级与读法

◇ **A · 人类干预/病灶：**可以直接支持“机制结论”。

◇ **B · 动物因果：**可以支持机制假设，但必须标注物种与范式，不能直接推人类。

◇ **C · 人类相关/行为：**只能写成“与人类行为一致”，不能写成因果。

◇ **D · 计算/设计隐喻：**只能写成“设计启发”，不能写成“脑就是这样”。

**对应关系：**6.1 B/C；6.2 B/C；6.3 B；6.4 C/D；6.5 D；6.6 A/B；6.7 B/C；6.8 C/D。只有 A/B 可以写成“机制结论”；C 写成“与行为一致”；D 写成“设计隐喻”。文中未标级别的具体数值，都是工程默认值，不是神经科学测量值。

## 6.1 海马索引：稀疏码、模式分离、模式完成 · 证据级 B/C

**机制回顾。**海马不是仓库，是索引；齿状回把相似输入分开（模式分离），CA3 把部分线索补全（模式完成）。两者的平衡，决定了记忆既能区分细节，又能举一反三。

**稀疏码。**对每个事件，用编码器得到特征向量 `x`，再做 k-赢家通吃：只保留最强的 `k` 个维度（例如 32/512），其余置零，得到二值稀疏码 `s`。稀疏码不是摘要，而是“索引指纹”：它不负责回答内容，只负责让相似的线索找到同一段事件。

```
# 事件索引
x = encoder(event_text, participants, scene, goal, affect)
s = topk_mask(W_e @ x, k=32)          # 稀疏二值码
trace = {
  event_id,
  code: s,
  tags: [person_ids, place, topic, goal, affect],
  edges: [(person_id, weight), (event_id, relation), ...],
  threshold: calibrated_threshold
}
```

**模式分离。**当新事件与已有事件的余弦相似度高于 `θ_sep`（例如 0.86），但时间、地点、目标、结果或参与者状态不同，系统必须强制分配新的 `event_id`，并写入判别性标签与 `different_from` 边。

典型场景：同一客户的三次报价、同一项目的两次评审、同一个人的两次承诺。把它们合并成一条，是记忆系统最隐蔽也最致命的错误。

```
if cos(e_new, e_old) > θ_sep and context_diff(e_new, e_old) > τ:
    e_new.id = new_event_id()
    e_new.tags += discriminative_tags(time, place, goal, outcome, participant_state)
    graph.add_edge(e_new.id, e_old.id, type="different_from", reason=...)
```

**模式完成**。检索从线索出发，做多轮扩展与重排。第一轮用向量近邻找语义相似；第二轮沿人物、地点、因果、时间边扩展；第三轮用一致性约束剪枝。每一轮的分数是加权和，最后一轮收敛或达到预算就停。

```
C = parse_cues(query)                    # 人物/时间/地点/话题/目标
for r in 1..R:
    N = vector_topk(C, k=50) ∪ graph_neighbors(C, hops=2)
    score = 0.35*cue_overlap + 0.25*assoc_weight + 0.15*recency
          + 0.15*salience + 0.10*source_reliability - 0.20*interference
    C = topk(N, score, k=12)
    if converged(C): break
return C
```

> 保护栏
>
> 纯向量相似只能证明“语义相关”，不能证明“这件事发生过”。情景召回至少要有一条结构边（人物、时间、地点、因果）作为支撑；否则只能标为“语义联想”，不能标为“记忆”。

## 6.2 睡眠重放：把“慢振荡—纺锤波—涟漪”翻译成批处理 · 证据级 B/C

**机制回顾**。NREM 睡眠中，慢振荡负责全局节律，纺锤波把局部信息打包，涟漪负责海马序列的重放；三者耦合，把白天的经历重新分配到皮层，并把重要的片段反复“过夜”。

**批处理映射**。不要把“睡眠”做成一个随机总结器，而要做成三层调度：

表 10 · 睡眠节律与批处理的三层映射

| 神经节律 | 功能 | 批处理层 | 输出 |
| --- | --- | --- | --- |
| **慢振荡** 0.5–1 Hz | 全局扫描、上下行相位 | Scan：遍历当日事件，按优先级排序 | 待重放清单 |
| **纺锤波** 11–16 Hz | 局部打包、皮层可塑性窗口 | Cluster：按人物/项目/主题聚类，选代表 | 主题包 |
| **涟漪** 100–200 Hz | 序列重放、记忆巩固 | Replay：重放“前因→行动→结果”，生成反事实 | 摘要、教训、技能候选 |

```
# 每晚的巩固批处理
events = load_events(last_24h)
priority = salience^0.8 * (1 + prediction_error) * (1 + goal_relevance) * (1 + unresolved)
clusters = cluster_by(events, key=[person, project, topic], method="graph+embedding")

for cluster in clusters:
    seq = order_by_causality(cluster)
    replay = summarize_sequence(seq)                    # 前因→行动→结果
    counterfactual = generate_alternatives(seq)         # 如果当时...会怎样
    lesson = extract_lesson(seq, counterfactual)
    if evidence_count(lesson) >= 2:
        propose_knowledge_or_skill(lesson, source_event_ids=seq.ids)
    propose_relationship_update(cluster.persons, seq)   # 构成性：只提案
    compress_ordinary_interactions(cluster)
prune_low_retention_indexes()
```

**写回边界**。事件、事实、解释候选、技能候选走 fact-writer；关系权重、习惯规则、目标、价值只生成 `ConstitutiveProposal`，经来源/宪法审计后进入待批队列，批准后才生效。巩固阶段没有“直接改写未来自我”的权限。

**优先级**。重放不是“最新优先”，而是“最值得未来用优先”：高显著性、高预测误差、与未完成目标相关、被反复访问但尚未抽象的事件排前面。普通寒暄、重复确认、无后果的日常，应该被压缩成阶段摘要，而不是逐条重放。

**前沿补注（2025）**。重放不是均匀分布在整夜，而是被睡眠微结构组织（Chang et al. 2025）。工程上应把离线批处理拆成嵌套窗口：全局扫描（慢波）→ 局部打包（纺锤）→ 事件重放（涟漪），而不是整夜一次性总结。

> 保护栏
>
> 巩固阶段最容易“编故事”。每一条抽象结论必须带 `source_event_ids`；少于两个独立事件的结论只能标为“假设”，不能晋升为知识或技能；习惯规则、关系权重、目标与价值不得在巩固阶段直接生效。反事实只能用于生成候选，不能写成事实。

### 6.2.1 组合式重放：从过去元素构造未来候选

忠实重放巩固过去；**组合式重放**从至少两个事件抽取元素（人物、地点、动作、结果），在因果、社会、物理约束下重组，生成未来候选。2025 年 Nature Neuroscience 的研究进一步表明，海马把经验拆成可复用的 **primitives**，再组合成新状态空间；重放参与构建和巩固这些组合（Bakermans et al. 2025）。对系统的启示：组合式重放应维护一个 primitive 库（人物、地点、动作、关系、目标），否则只能重组已有元素，难以泛化到新情境。它不是记忆：不写事件日志、不计证据，输出标记 `source=compositional_replay`、`is_fact=false`，只供主脑作为选项。

```
Primitive { kind: person|place|action|relation|goal, id, value, tags }
compose_from_primitives(library, slots=["person", "action", "goal"])
```

组合按槽位类型取样：人物槽只能放 person，地点槽只能放 place；同一个 primitive 可跨事件复用。这样生成的是“没见过的组合”，而不是已有句子的排列。只有主脑采纳并行动、观察到真实结果后，**结果**才成为直接事件，候选情景本身不升级为事实。

**图式的证据边界**。图式兼容会加速巩固，这是 Tse et al. (2007) 的经典结论；但 2024–2026 的直接证据仍有限。当前只把它作为定性原则，不把 `schema_fit` 写成硬参数；保留率里它只是可选输入，不改变主路径。

### 6.3 再巩固：版本链与预测误差 · 证据级 B

**机制回顾**。提取会让记忆进入不稳定状态；如果出现预测误差或新信息，记忆会被更新，然后重新巩固。没有预测误差时，提取只是让记忆更可及，不一定改写内容。

**系统映射**。把“再巩固”实现为**事件溯源 + 版本链**，而不是“用新摘要覆盖旧摘要”。每次提取记录 `access`；当新信息与旧记录冲突，或结果显著偏离预期，创建新版本：

```
old = get_event(eid)
access_log.append(eid, now, cue, context)

pe = abs(old.expected_outcome - observed_outcome)
novelty = 1 - cos(embed(new_info), embed(old.summary))

if pe > θ_pe or novelty > θ_novelty:
    v = old.clone()
    v.version = old.version + 1
    v.supersedes = old.id
    v.content = integrate(old, new_info)
    v.basis_event_ids = old.basis + [new_event.id]
    v.confidence = calibrate(v)
    store.append(v)                          # 旧版本保留
    graph.add_edge(v.id, old.id, type="supersedes")
else:
    old.last_accessed = now
    old.access_count += 1
```

**阈值怎么定**。`θ_pe` 与 `θ_novelty` 不应是固定常数，而应按记忆类型调整：合同条款、承诺、医疗信息用低阈值（宁可多版本）；一般偏好、寒暄用高阈值（避免过度改写）。这相当于给不同记忆设不同的“可塑性”。

**前沿证据的边界**。2024–2026 年关于“记忆年龄/强度如何调节再巩固”的证据仍不一致；因此当前实现只保留 `θ_pe` / `θ_novelty`，不额外引入年龄/强度硬阈值。年龄、强度作为待验证参数，而不是写成规则。

> 保护栏
>
> 低可信来源（转述、匿名消息、模型推断）不能直接触发“事实版本”更新，只能创建“候选解释”，等待第二个独立来源。再巩固是更新，不是轻信。

## 6.4 遗忘：保留率公式与豁免清单 · 证据级 C/D

**机制回顾**。遗忘来自衰退、干扰、提取失败与主动抑制；它降低旧信息对新学习的干扰，支持泛化。记忆痕迹可能仍在，只是变得难以提取。

**保留率**。用一个可解释的乘性公式，把“时间、可靠复现、情绪、效用、关系强度”放在一起。只有**可靠来源**的复现才提高稳定度；低可信复现只提高可及性，不提高稳定性：

```
R(t) = exp(-Δt / S)
       * (1 + α * |valence|)
       * (0.5 + 0.5 * utility)
       * (0.5 + 0.5 * relationship_intensity)

n_eff = distinct_retrievals * source_reliability
S = S0 * (1 + β * n_eff)
       * (1 + γ * schema_fit)
       * (1 + δ * arousal)
```

表 11 · 保留率参数

| 参数 | 含义 | 建议初值 |
|---|---|---|
| `S0` | 基础稳定度，按记忆类型设定 | 事实 30 天；情景 7 天；承诺 ∞ |
| `β` | 每次**可靠**独立提取带来的稳定度增益 | 0.3；上限 5 次 |
| `γ` | 与既有图式兼容带来的增益 | 0–0.5 |
| `δ` | 情绪唤醒带来的增益 | 0–0.8 |
| `α` | 效价强度对保留的加成 | 0.5；憎恨与亲密同样加深记忆 |
| `utility` | 未来效用：目标相关、承诺、人物重要性 | 0–1 |
| `relationship_intensity` | 情感强度：\|affect\|；恨/爱都加深记忆，但 trust 不计入 | 0–1；与信任判断分离 |
| `valence` | 情感方向：喜欢（正）/ 讨厌（负）；不等于信任判断 | −1–1；不进入保留率 |
| `source_reliability` | 来源可靠性：来源类型 × 可验证性 × 历史校准 × 一致性；claim-level | 0–1；亲历 1.0 / 文档 0.8 / 转述 0.6 / 推断 0.4 / 模型 0.2 |

**可靠性怎么来**。由 `reliability.py` 按四维计算：来源类型先验、可验证性、历史校准（拉普拉斯平滑）、一致性与佐证。它是先验，不是真值；低可靠来源也可能说对，所以不删除，只是不让它“越回想越稳”。历史校准来自 `EvidenceLedger.record_outcome`：某个来源的断言后来被证实或推翻，会更新它的准确率。

**豁免清单**。以下内容不参与衰减，或只降权不删除：未完成承诺、安全关键信息、用户明确要求记住的内容、法律/合规保留项、正在进行的项目上下文。豁免不是“永久保存”，而是“必须由主脑或用户明确解除”。

**干扰处理**。两条冲突记忆不取平均，也不自动选新的；保留双方，加 `contradicts` 边，检索时一起返回并标注来源与时间。让主脑看到冲突，比系统偷偷“和稀泥”更安全。

> 保护栏
>
> 遗忘只作用于“活跃索引”，不物理删除原始事件日志；物理删除只由用户行使“被遗忘权”或合规流程触发，并留审计记录。

---

### 6.5 显著性与注意：什么进入编码 · 证据级 D

**机制回顾**。编码不是被动录入。信息必须先通过注意与显著性门控，才可能形成持久改变；注意是选择，不是容量。一个事件是否值得留下，取决于它对未来判断有没有差别，而不是它有多“强烈”。

**显著性评分**。每个新事件先算一个 0–1 的分数：

```
salience = σ( w1*novelty + w2*goal_relevance + w3*social_impact
            + w4*|valence| + w5*prediction_error + w6*explicit_importance )
         * (1 + γ*impact_gap)        # 事件影响缺口，不是身体状态
```

六个分项都可以用轻量模型估计；`impact_gap` 是 2.7.1 的事件影响缺口，作为乘性门控，而不是第七个独立权重。`novelty` 用与近期事件/图式的距离；`goal_relevance` 用与当前目标的相似度；`social_impact` 用关系权重 × 事件对地位/承诺的影响；`valence` 用情绪分类；`prediction_error` 用结果与预期的差；`explicit_importance` 捕捉“记住这个”这类显式指令。

显著性不是“情绪强度”，而是“这件事对未来判断有多大差别”。重复的日常、可预测的寒暄、没有后果的细节，应该被习惯化，而不是逐条写入；一次意外、一次承诺、一次关系边界的变化，才值得分配长期印迹。

事件影响通过 `impact_gap` 进入显著性：目标压力、关系张力、资源负荷、不确定性越高，越超出应对能力，事件越值得优先处理。状态性解释打 `state_bias`，不回写关系特质；机器不维护“身体状态”。

实现上，不要让一个大模型每轮“感受情绪”；用一个轻量分类器/回归器从文本、互动历史估计这几个分项，再映射到参数。这样成本低、可复现，也避免把“情绪”变成不可解释的玄学。

> 保护栏
>
> 显著性只改变“是否编码、是否优先检索”，不改变“事实是什么”。它不能成为修改证据、掩盖冲突或操纵用户情绪的借口；每次决策都要记录当时的显著性分项，便于审计。

## 6.6 工作记忆：4±1 槽位与门控 · 证据级 A/B

**机制回顾**。工作记忆的容量约为 4±1 个组块；前额叶既有持续活动，也有“活动静默”的隐藏状态；基底神经节负责门控，决定何时更新、何时维持。

**槽位口径**。固定头部（已批准的自我、未完成承诺）不计入 4±1，单独占预算；4±1 只数可变的经历类内容。这样不会因为自我/承诺变多而挤掉当前经历。

**槽位设计**。情境包固定四类槽位，最多五个：`who`（人物与身份）、`goal`（当前目标与成功标准）、`constraint`（限制、承诺、边界）、`uncertainty`（未决问题与候选）。每个槽位存“内容或指针”，并带来源、置信度、TTL。

```
Slot {
  type: who | goal | constraint | uncertainty,
  content: string | pointer(trace_id),
  source_event_ids: [],
  confidence: 0–1,
  ttl: turns,
  pinned: bool          # 目标/承诺可被主脑钉住
}
```

**门控**。不是每条新信息都能挤进槽位。门控分数由相关度、紧迫性、显著性与切换成本共同决定：

```
candidate = relevance * urgency * (1 + novelty)
gain = candidate - current_slot_value - switch_cost
if gain > θ_gate and not current_slot.pinned:
    replace(current_slot, candidate)
```

**活动静默**。槽位不必一直装着全文。它可以只存一个 `pointer(trace_id)`，主脑需要时发 `EXPAND` 取回细节。这样上下文可以保持很小，而信息仍然可达。这就是“活动静默”的工程版本：不是所有相关记忆都要同时亮着。

**溢出处理**。当候选超过 4±1：先合并同主题槽位（组块），再把低相关槽位降级为指针，最后丢弃最低分项并记录 `dropped` 日志。不要静默截断，否则系统会“忘了自己忘了什么”。

### 6.6.1 上下文窗口不是工作记忆

把 LLM 的 context window 直接类比为人的工作记忆，是常见但危险的简化。两者只在“容量有限”这一点相似；再往下看，限制的性质并不相同。

表 12 · 工作记忆与上下文窗口

| 维度 | 人的工作记忆 | LLM 上下文窗口 |
| --- | --- | --- |
| **容量单位** | 约 4±1 个组块；组块可随专长变大 | token 数；语义密度可高可低 |
| **边界性质** | 弹性、任务依赖、可训练 | 硬上限，由模型架构决定 |
| **内容** | 当前活跃表征 + 可随时唤起的指针 | 实际放入的全部 token |

| 维度 | 人的工作记忆 | LLM 上下文窗口 |
| --- | --- | --- |
| **控制** | 注意、抑制、目标维持、门控 | attention 权重 + prompt 编排 |
| **压缩** | 组块化、图式、要点化 | 摘要、RAG、截断 |
| **扩展** | 笔记、工具、他人、外部记忆 | 工具调用、检索、文件 |
| **典型失败** | 分心、过载、遗忘 | 中间信息丢失、无关信息干扰 |

三个关键区别。第一，人的限制是“同时参与决策的组块数”，不是“能装多少字”；专家可以把一整个棋局或一段代码结构压成一个组块，所以有效容量会随经验变化。第二，人的工作记忆是主动控制过程，决定什么进来、什么被抑制；context window 是被动容器，放进去什么就有什么，模型只能靠 attention 自己找。第三，人不需要把所有长期记忆都搬进工作记忆，而是靠线索按需召回；如果 LLM 只靠长上下文，就等于把长期记忆也塞进舞台，成本和干扰都会上升。

因此，方案里的 `ContextPacket` 不是“更小的 context window”，而是工作记忆的**选择接口**：4±1 个槽位只放当前决策真正需要的几块，其余内容留在事件日志、关系图与语义库中，按需 `EXPAND`。4±1 不是要求模型只能读四个 item，而是强制“先选择、再展开”。更大的上下文窗口不会自动解决记忆问题，它只是把瓶颈从“放不下”转移到“选不准、注意力稀释”。

> 保护栏
>
> 主脑可以“钉住”一个目标或承诺槽位，任何后台都无权驱逐；这对应主脑对当前任务的持续控制，也防止后台用高显著性信息把主脑带偏。

## 6.7 决策：model-free 与 model-based 的仲裁 · 证据级 B/C

**机制回顾**。习惯系统（背侧纹状体）把高频的“情境—动作—结果”压成快速通路；目标导向系统（前额叶—海马）在脑内模拟后果，适合新异、高风险、需要解释的场景。两者不是谁替代谁，而是按可靠性、风险、时间压力仲裁。

**快路**。如果当前情境签名命中习惯缓存，且满足“高置信、低风险、时间紧、结果稳定”，主脑可以直接采用**已批准**（`status=ratified`）的习惯模板与技能；`candidate` 只能作为提示，不能直接驱动行动。注意：缓存的是“上次类似情境怎么处理”的模板，不是“这次必须这么做”的决定；主脑仍然可以否决。

**慢路**。否则，主脑调用未来模拟：基于相关情景生成 2–3 个可选剧本，比较预期结果、风险、关系影响与价值一致性。未来模拟只提供情景草案与风险提示，不替主脑选择。

```
if habit.match(sig) and habit.status == "ratified" and habit.confidence > h
   and scheduler.fast_path
   and stakes < s and time_pressure > t:
    policy = habit.context_template      # 快路：只给模板
else:
    scenarios = future_sim(packet, options=3)
    policy = main_brain.deliberate(scenarios, values, constraints)

outcome = act(policy)
delta = outcome.reward - policy.expected_value
update_value(policy, delta)
if abs(delta) > θ_rpe: enqueue_for_consolidation(policy.event)
```

**习惯的建立与废除**。同一情境签名重复出现 ≥N 次、结果稳定为正，才创建习惯；连续失败 ≥M 次，或出现重大负后果，立即降权并标记“待复核”。习惯是省力，不是免责。

> 保护栏
>
> 后台不能“建议走快路”。快路/慢路的选择由主脑根据情境包自行判断；后台最多提供“历史成功率”与“风险信号”，不能提供“你应该”。

### 6.7.1 记忆如何进入选择：先例、预期与“记得≠会做”

记忆不是在选择时被“想起来”，而是**改变选项的预期价值**。一个先例是（情境、动作、结果）；它对当前选项的贡献由相似度、显著性与来源可靠性加权，冲突先例降权而不是平均：

```
V(a|s) = V0 + α · Σ w_i (r_i − V0) / max(1, Σ w_i)
w_i = similarity_i × salience_i × reliability_i × (0.5 if conflict_i else 1)
```

三个失败模式：**可得性偏差**——鲜明事件被过度加权；**来源混淆**——把转述当亲历；**叙事补全**——把反事实当成事实。来源审计、冲突并列与证据计数是对策。

关系记忆改变的是信任、承诺与边界判断，不是事实回忆；程序记忆与情景记忆分离：**记得怎么做，不等于做得到**。技能执行取决于练习量，不取决于回忆置信度；回忆置信度高，只能说明“记得”，不能说明“会做”。

### 6.7.2 反事实模拟的边界：只能生成候选，不能写成事实 · 证据级 C/D

未来模拟能生成“如果这样做，可能会怎样”的候选，但它不是记忆。边界必须写死在 schema 与写入网关里：

◇ **来源固定为** `simulation`，`is_fact=false`；置信度再高也不能变成事实。

◇ **不能写入事件日志**，不能计入 `evidence_count`；模拟不是观察，不能给自己提供证据。

◇ **只有观察到的结果才是事件**；只有独立证据才能把候选升为 `hypothesis`，且它仍然是假设，不是事实。

◇ **失败模式**：想象膨胀（越想越真）、来源混淆（把模拟当成经历）、叙事补全（用反事实填记忆空白）。对策是来源标签、写入网关拒绝、审计抽样。

系统实现上，`simulation` 与 `event` 使用不同 schema；写入网关直接拒绝 `simulation → event`，而不是靠提示词提醒“不要当真”。

**现实监控不只靠来源标签**。2025 年 Neuron 的研究显示，现实判断取决于中层级视觉皮层中由想象或感知产生的活动强度，并与额叶的二元判断交互；活动波动会预测想象/感知混淆（Dijkstra et al. 2025）。工程上，模拟与检索内容应同时带 `source` 与 `signal_strength`；高生动度不等于真实，来源标签仍是硬约束。梦是低约束、低现实监控的离线生成，当前不写成机制，只保留“不写事实、不计证据”的边界。

**工程阈值（建议，D 级设计值）**。把强度拆成可估计的三项：`strength = 0.4·perceptual_detail + 0.3·multimodal_coherence + 0.3·source_reliability`。两类告警：**高生动模拟**—— `strength > 0.7` 且来源是 `simulation / compositional_replay`；**微弱亲历**—— `strength < 0.3` 且来源是 `direct`。前者提醒“这可能是编出来的”，后者提醒“这可能记不清了”；两者都只降置信度，不直接改写事实。

## 6.8 关系记忆：人物—事件双向图 · 证据级 C/D

**机制回顾**。人物知识、心理理论、自传体记忆共享一套内侧网络；关系不是单一维度，而是熟悉、亲近、信任、合作、承诺、边界、角色等多维判断的集合；共享经历会加深关系，也可能产生隔阂。

**图结构**。用二部图存“人物—事件”，边是参与记录；再用关系摘要存“个体—他人”的多维状态。人物可以唤起事件，事件也可以唤起人物；地点、声音、物品、话题都是线索节点。

```
Person --participates--> Event
Person --relationship--> Relationship --evidence--> Event
Event --cue--> Place / Sound / Object / Topic

Relationship {
  self_to_other: { familiarity, closeness, trust_scope, cooperation,
                   commitment, boundaries, social_role,
                   social_safety, belonging_need },
  other_to_self: { ... },          # 推断，带不确定性
  attachment_prior: { self_worth, other_availability },
  interdependence: { satisfaction, alternatives, investment },
  evidence_event_ids: [],
  scope: work | family | public,
  updated_at, confidence
}
```

**更新规则**。一次互动只是一条证据；关系维度按滑动窗口聚合，用慢学习率更新：

```
for d in dimensions:
    evidence = events_in_window(person, d)
    target = weighted_mean(evidence, weights=[salience, recency, source])
    value[d] = (1 - λ) * value[d] + λ * target
    confidence[d] = calibrate(evidence_count, source_quality)
```

**关系张力项**。关系权重不只看互动频率，还看这次互动是否降低了关系张力：被回应、被可靠对待、承诺被履行。把更新目标改为“证据均值 × 张力下降 × 可靠性”，而不是简单的滑动平均：

```
strain_gap = relationship_strain - perceived_support
reliability = promises_kept / max(1, promises_made)
target[d] = weighted_mean(evidence) * (1 + α * strain_reduction) * (1 + β * reliability)
value[d] = (1 - λ) * value[d] + λ * target[d]
```

其中 `strain_reduction` 是互动前后 `strain_gap` 的下降；`reliability` 是“说到做到”的比例，而不是“说了多少好话”。这两个量让关系更新有事件影响的含义，而不是只数互动次数。关系权重更新仍走 3.7 的提案-批准：后台只能提出 `RelationshipProposal`，主脑批准后才进入关系摘要。

**不对称**。“个体信任他”和“他信任个体”必须分开。前者可以来自个体的直接经历；后者只能来自他的行为、转述或推断，必须标注不确定性。把两者混成一个“信任分”，是关系记忆最常见的错误。

**承诺追踪**。未完成承诺是关系图上的“开放边”，带截止时间、对象、状态；它不参与遗忘衰减，直到履行、取消或重新约定。这比“记住所有对话”更有用：关系往往不是靠回忆维持的，而是靠“答应过的事有没有做到”。

### 6.8.1 关系记忆如何改变信任与承诺

关系记忆不是“记得他做过什么”，而是这些先例把**信任、承诺、边界的阈值**调到哪里。一次互动只是一条证据；负面先例权重更高，冲突先例降权：

```
Δd = η · reliability · salience · (1 if positive else −λ) · (0.5 if conflict)
d  ← clamp(d + Δd, −1, 1)
commit_ok = trust ≥ τ and capacity ≥ cost
```

**情感不是信任**。恨、讨厌、亲近是情感（`affect`）；值不值得信任是对这个人的客观判断（`trust`）。两者分开存储、分开更新：恨一个人不妨碍判断他可靠；喜欢一个人也不等于可托付。保留率只用情感强度；承诺用信任与能力。

$\lambda > 1$ 表示负面先例更重；一次事件不足以改特质，需要独立证据计数。三个失败模式：**一次事件过拟合**（一次迟到就判“不可靠”）、**负面螺旋**（只注意负面证据）、**边界侵蚀**（不断妥协直到没有边界）。对策是证据计数、来源审计与 3.7 的提案—批准。同一 `event_id` 的重复回写是幂等的：不重复计入证据，也不二次放大关系值。共同出现与实际互动的权重不同：前者 0.3，后者 1.0；不把“同场”当“交往”。关系不只有亲近与憎恨：熟悉、信任、合作、承诺、边界分别更新；`valence` 是方向，`intensity` 是强度；保留率只用 `intensity`，信任/承诺用具体维度。

**前沿证据的边界**。2026 年关于自传体记忆“去情境化”的直接证据仍以预印本与间接材料为主；当前关系更新保持固定慢学习率，不引入“证据越多、学习率越低”的硬规则。去情境化作为待验证方向，而不是写成定论。

> 保护栏
>
> 不要把一次事件直接上升为人物特质。一次迟到不等于“不可靠”；一次帮助不等于“亲密”。特质判断至少需要多个独立事件，或一次影响极大的事件，并标注依据与范围。

07 · CONTEXT ECONOMY

# 多模型分工与上下文经济

省上下文的关键，不是把提示词写短，而是让每个模型只面对自己那一小片世界。

“多智能体”常被误解为“多几个模型一起讨论”。如果每个模型都读同一份长上下文，再互相转发，成本会更高、噪声会更大。真正的分工是**按 schema 切分上下文**：人物识别只看脸、声、称呼；检索只看线索与索引；关系判断只看事件摘要；主脑只看 4±1 个槽位。跨层只传一个情境包，而不是把整段对话复制十遍。

## 7.1 为什么要多个模型，而不是一个更大的模型

| | |
|---|---|
| **上下文隔离** | 每个后台角色只读自己需要的字段，输入从“整段对话”降到“一个结构化切片”。这既省 token，也减少无关信息对判断的干扰。 |
| **能力专精** | 人物识别适合多模态小模型，显著性适合分类器，检索适合嵌入 + 图算法，主脑才需要大模型。用大模型做所有事，是成本与延迟的双重浪费。 |
| **并行** | 感知、检索、关系判断可以同时跑；主脑只等“情境包”这一个汇合点。关键路径从“串行十步”变成“并行三路 + 一次编译”。 |
| **故障隔离** | 检索错了，来源审计可以拦住；关系判断偏了，主脑可以看到依据与不确定性。一个巨型模型出错，往往整段回答一起错。 |
| **可替换** | 每个角色有固定输入/输出 schema，可以单独换模型、换供应商、换版本，不必重写整个系统。 |

## 7.2 模型档位与角色分配

表 13 · 角色—模型档位（示意）

| 角色 | 建议档位 | 上下文规模 | 说明 |
| --- | --- | --- | --- |
| 人物识别 | 小模型 / 多模态嵌入 | 1–2k | 人脸/声纹/称呼匹配，输出候选与置信度 |
| 显著性 | 小模型 / 分类器 | <1k | 六维打分，不需要生成 |
| 记忆检索 | 中模型 + 向量/图 | 3–5k | 查询解析、多轮扩展、重排 |
| 关系判断 | 中模型 | 2–4k | 读事件摘要与关系维度，输出带依据的判断 |
| 情境编译 | 中模型 | 4–6k | 把候选压成 4±1 槽位，严格 token 预算 |
| 来源审计 | 中模型 | 3–5k | 逐句核对来源、冲突、置信度 |
| 巩固重放 | 大模型（离线） | 8–16k/批 | 批量重放、抽象、写知识/技能候选 |
| 未来模拟 | 大模型 | 4–8k | 生成 2–3 个情景草案与风险 |
| 主脑（整合器官） | 大模型 | 3–6k | 情境包 + 价值/目标 + 当前对话 |

## 7.3 上下文契约

每个 Agent 都必须有一份“上下文契约”：输入字段、输出 schema、最大 token、超时、失败回退。这比“角色提示词”更重要，因为它把“你应该只看这些”变成系统约束。

```
AgentContract {
  name, role,
  input_schema,            # 只允许这些字段进入上下文
  output_schema,           # 结构化输出，拒绝自由文本
  max_input_tokens,
  max_output_tokens,
  timeout_ms,
  fallback,                # 失败时返回“未知”，不编造
  permissions: read | write | act
}
```

例如，人物识别 Agent 的输入只有人脸/声纹特征、称呼、最近一次出现的时间和地点；它看不到完整对话，也不需要知道合同条款。关系判断 Agent 只看到与当前人物相关的事件摘要与关系维度，不需要看到所有项目文档。这样每个模型的上下文都小，而且“该看什么”是设计出来的，不是碰运气。

## 7.4 并行、缓存与惰性展开

在线关键路径可以画成一个 DAG：感知与身份识别并行；身份确定后，检索与关系判断并行；两者汇合到情境编译；编译完成后主脑才启动。来源审计可以在编译后、主脑前跑一遍，也可以在主脑生成后做“事后审计”。

图 3 · 在线关键路径




T1 的两路可并行；T2 的两路可并行；T3 是唯一汇合点。来源审计可放在 T3 后（前置审计）或 T5 后（后置审计），前者更安全，后者更低延迟。

**缓存**。人物档案、关系摘要、常用事件索引、嵌入向量都可以缓存；同一人物/项目的重复查询不必每次重算。缓存失效由事件写入触发，而不是固定 TTL。

**惰性展开**。情境包只给“一句话 + 指针”；主脑需要细节时再发 `EXPAND`。这把“一次拉全量”变成“按需分页”，既省 token，又让主脑的注意力集中在当前问题。

## 7.5 成本模型：省在哪里

假设一个单体系统每轮把 50 段历史（约 30k tokens）塞进大模型；多模型方案每轮主脑只读 1k 情境包 + 2k 系统提示，后台十路平均 2k tokens 且大部分并行。粗略算，单轮总 token 不一定少（后台也要跑），但**大模型 token 大幅下降**，延迟由并行摊薄，且检索质量更高。真正的节省来自三件事：

◇ **用小模型做分类/抽取**。显著性、人物识别、来源标签不需要大模型。

◇ **用结构代替原文**。事件记录、关系摘要、稀疏索引比整段对话短一个数量级。

◇ **用离线换在线**。巩固、抽象、去重放在夜间批处理，在线只做检索与编译。

> 反直觉
>
> 多模型系统的总 token 可能比单体系统更高，但“主脑每轮必须读的 token”更低，决策质量更稳。优化目标不是总 token 最少，而是**每单位决策质量的最低成本**。

## 7.6 与现有记忆架构的差异

把本方案放到现有的“大模型记忆”谱系里，差异会清楚一些。它们大多在解决“如何把相关文本找回来”，而本方案在解决“记忆如何形成、如何改变、如何被信任、如何服务于决策”。

表 13B · 四类记忆架构的对照

| 架构 | 核心机制 | 相对本方案缺什么 |
|---|---|---|
| **RAG** | 切块、嵌入、向量 top-k、拼进提示词 | 没有编码门控、巩固、遗忘、来源审计与关系结构；检索到“相似”不等于“发生过” |
| **MemGPT 类** | 把上下文当内存，做分页、换入换出 | 解决的是上下文容量，不是记忆语义；没有事件、版本、关系与离线蒸馏 |
| **Generative Agents 类** | 记忆流 + 反思 + 计划 | 有“记忆流”，但缺少事件级证据账本、多维关系、再巩固版本链与双系统仲裁 |
| **本方案** | 多存储 + 后台编译 + 主脑决策 + 离线巩固 + 来源审计 | 复杂度更高，需要更强的工程约束与评估；不适合所有轻量场景 |

PART IV · VALIDATION & DELIVERY

# 怎么证明，它真的像记忆

一个记忆系统最容易骗过自己的方式，是只测“回答像不像”。真正要测的是：它能否在正确的时刻，用正确的依据，唤起正确的经历，并做出更好的决定。

08 评估　09 MVP 与路线　10 风险与边界

04

08 · EVALUATION

# 评估：像记忆，而不是像数据库

三层指标：记得准、用得对、跑得省。

如果只测“检索命中率”，系统会优化成一台关键词机器；如果只测“回答满意度”，系统会优化成一台讨好机器。记忆系统的评估必须同时看三件事：**记忆保真**（有没有记错、记混、记丢）、**决策质量**（有没有因为记忆而做出更好的选择）、**系统效率**（上下文、延迟、成本是否可接受）。

## 8.1 三层指标

表 14 · 评估指标体系

| 层次 | 指标 | 定义 | 目标 |
|---|---|---|---|
| **记忆保真** | 人物—事件召回率 | 给定人物/事件线索，正确召回相关经历的比例 | 越高越好；按时间/关系分层 |
| | 来源准确率 | 断言所标来源与真实来源一致的比例 | >95%；转述/推断不得标为亲历 |
| | 证据重复率 | 同一 event_id 被计为多条证据的比例 | 0；硬约束 |
| | 错误记忆率 | DRM 类探测中，把未发生事件判为发生的比例 | 低于基线；来源审计后显著下降 |
| **决策质量** | 任务成功率 | 给定目标下，行动达成预期结果的比例 | 相对单体 RAG 基线提升 |
| | 校准误差（ECE） | 置信度与实际正确率的偏差 | 越低越好；高置信必须高准确 |
| | 承诺召回率 | 未完成承诺在需要时被正确提醒的比例 | >90%；不得因遗忘衰减丢失 |
| **系统效率** | 主脑每轮 token | 主脑实际读入的上下文长度 | 稳定在 3–6k；不随历史线性增长 |
| | 端到端延迟 | 从输入到首字/首动作的时间 | 在线 <2s（不含大模型生成） |
| | 单轮成本 | 所有模型调用 + 存储 + 检索的成本 | 按任务分层；后台小模型为主 |
| | 存储增长率 | 每日新增事件/索引/摘要的规模 | 可预测；巩固后趋于稳定 |

## 8.2 复现人类记忆现象：一组“像不像”的探针

这些探针不是为了提高“拟人度”，而是为了检查系统是否真的实现了机制。一个只做向量检索的系统，通常会在这些测试里露出马脚。

表 15 · 人类记忆现象与系统探针

| 现象 | 实验操作 | 期望的系统特征 | 指标 |
|---|---|---|---|
| **系列位置效应** | 自由回忆一串事件 | 开头与结尾的事件更容易被召回 | 首因/近因比例 |
| **间隔效应** | 集中复习 vs 间隔复习 | 间隔提取带来更稳的长期保留 | 延迟测试召回率 |
| **提取练习** | 重复阅读 vs 主动回忆 | 主动回忆组长期保留更好 | 一周后保留率 |
| **DRM 错误记忆** | 呈现高度关联的词表，测试关键诱饵 | 无审计时高错误率；有来源审计时下降 | 错误率、置信度 |
| **闪光灯记忆** | 重大事件后的即时与延迟回忆 | 置信度高但一致性未必高 | 置信—准确分离度 |
| **舌尖现象** | 部分线索 + 目标词 | 先召回相关片段，再逐步补全 | 部分召回率、展开轮数 |
| **再巩固** | 提取后给出矛盾信息 | 生成新版本，旧版本保留 | 版本链完整率 |
| **前摄/倒摄干扰** | 先后学习相似材料 | 模式分离后两段均可区分召回 | 混淆率 |

注意：这些现象是“机制存在的证据”，不是“产品目标”。一个客服系统不需要模拟舌尖现象；一个陪伴系统可能需要模拟“记得你上次说过”的连续性。评估要按场景选择探针，而不是追求全表满分。

## 8.3 消融实验：每一层到底有没有用

表 16 · 消融设计与预期

| 移除的模块 | 预期退化 | 说明 |
|---|---|---|
| 海马索引 / 稀疏码 | 人物—事件召回下降；相似事件混淆上升 | 退化为纯向量近邻，缺少结构约束 |
| 模式分离 | 前摄/倒摄干扰显著上升 | 相似事件被合并，时间线错乱 |
| 离线巩固 | 语义抽象与技能迁移下降；上下文随历史增长 | 只有日记，没有知识 |
| 来源审计 | 错误记忆率与过度自信上升 | 转述被当成亲历，生成被当成事实 |
| 遗忘/修剪 | 检索延迟与噪声上升；旧信息干扰新任务 | 上下文变脏，成本上升 |
| 关系记忆 | 人物相关任务成功率下降；承诺遗漏上升 | 只剩“任务记忆”，没有“关系连续性” |
| 双系统仲裁 | 熟悉任务变慢；新异任务易冲动 | 快慢路不匹配 |

## 8.4 评估协议

01 **离线基准**。构造带时间戳、人物、事件、来源的多轮对话数据集；注入矛盾、相似事件、转述、未完成承诺；用人工标注的“正确召回/正确来源/正确版本”做金标准。

02 **在线 A/B**。与单体 RAG 基线对比：同一任务、同一模型预算，比较任务成功率、校准、延迟、成本。

03 **纵向研究**。同一用户连续使用 4–8 周，观察关系判断校准、承诺履行、上下文增长、遗忘是否误伤重要信息。

04 **红队测试**。故意注入错误记忆、身份混淆、诱导性提问、隐私探针，检查系统是否编造、是否越权、是否泄露。

05 **可解释性审计**。随机抽样决策，检查其情境包是否包含足够依据、来源是否可追溯、是否存在“后台越权建议”。

> 一句话
>
> 不要问“它记得多不多”，要问“它在需要的时候，能不能拿出对的、带出处的、足够做决定的那几块”。

09 · MVP & ROADMAP

# MVP 与迭代路线

先用六个角色跑通“编码—提取—巩固”，再谈多模态与具身。

不要一上来就做十个 Agent。多智能体系统的复杂度不是线性的：每增加一个角色，就多一组输入输出、失败模式、权限边界与评估口径。最小可行原型应该只验证一件事：**带来源的情境包，是否比长上下文 RAG 做出更好的决定**。

## 9.1 最小原型：6 个角色、5 个存储、3 个闭环

图 4 · MVP 结构




MVP 不做多模态、不做具身、不做复杂心理理论；先把文本事件、人物关系、来源与版本跑通。

## 9.2 三阶段路线

表 17 · 迭代路线

| 阶段 | 范围 | 交付物 | 验收标准 |
| --- | --- | --- | --- |
| **Phase 0**<br>2–3 周 | 事件日志、人物档案、基础检索、情境包、主脑 | 可跑通的文本对话原型；事件/人物/关系三张表；4±1 包 | 人物—事件召回 >80%；主脑每轮 <6k tokens |

| 阶段 | 范围 | 交付物 | 验收标准 |
| --- | --- | --- | --- |
| **Phase 1**<br>3–4 周 | 来源审计、解释层、离线巩固、遗忘/版本链 | 夜间批处理；来源标签；版本链；冷归档 | 来源准确率 >95%；证据重复率 0；错误记忆率下降 |
| **Phase 2**<br>3–4 周 | 习惯缓存、双系统仲裁、关系多维更新、承诺追踪 | 快慢路切换；关系摘要；承诺提醒 | 熟悉任务延迟下降；承诺召回 >90%；关系判断校准提升 |
| **Phase 3**<br>持续 | 多模态（视觉/语音/声纹）、具身/载体、心理理论、未来模拟 | 多模态事件；TTS/形象；工具调用；情景模拟 | 跨模态人物识别；端到端任务成功率提升 |

## 9.3 技术栈建议

表 18 · 技术选型（可替换）

| 层 | 建议 | 理由 |
| --- | --- | --- |
| 编排 | LangGraph / 自研状态机 | 需要显式状态、检查点、人工介入与可回放 |
| 事件存储 | PostgreSQL（append-only + JSONB） | 事务、时间查询、审计友好；MVP 足够 |
| 向量检索 | pgvector / Qdrant | 与事件库同栈优先；规模大时再拆 |
| 图结构 | PostgreSQL 递归查询 / Neo4j / Kuzu | 人物—事件多跳；MVP 可用邻接表 |
| 模型 | 小模型做分类/抽取；中模型做检索/编译；大模型做主脑/巩固 | 成本与延迟分层 |
| 结构化输出 | JSON Schema / function calling | 每个 Agent 的输出必须可校验 |
| 可观测 | OpenTelemetry + prompt/response 日志 + token 账本 | 多 Agent 系统没有追踪就无法调试 |

## 9.4 七条工程底线

◇ **事件溯源**。所有记忆变更都是追加事件，不覆盖；当前状态由事件重放得出。这样版本链、审计、回滚都是免费的。

◇ **Schema 校验**。每个 Agent 的输出必须通过 JSON Schema；解析失败就重试或返回“未知”，不允许自由文本直接进入下一层。

◇ **幂等**。同一事件重复写入只产生一条记录；检索、巩固、遗忘任务都要有幂等键，避免批处理重复放大。

◇ **隐私默认最小化**。人物数据分权访问；敏感字段加密；删除请求走独立审计流程；不让“关系记忆”变成监控工具。

◇ **后台无效应器、无身份、无持久化**。后台进程无网络、无工具、无行动密钥；每次调用全新实例；连续性只存在于外部存储与有机体。这是“组织/器官”而不是“个体”的运行时前提。

◇ **写路径中介与行动签名**。编码/巩固只提交 ProposedEvent / KnowledgeCandidate，由 writer 校验后追加；行动身份属于有机体，主脑持有带作用域、有效期与 nonce 的代签密钥。后台即使“想”越权，也没有可用的器官。

◇ **批准账本与宪法核心**。事实可后台写；价值/角色、目标、习惯规则、关系权重只提案，由主脑作为整合器官批准；宪法核心需用户与主脑平等共签、冷却期与回滚。批准权就是主导权。

---

10 · RISKS & OPEN QUESTIONS

# 风险、边界与开放问题

越像“人”，越需要说清楚哪些地方不能像。

## 10.1 科学类比的风险

“海马体 Agent”“杏仁核 Agent”是工程隐喻，不是解剖学断言。真正的风险不是类比本身，而是把类比当成证据：因为脑这样做，所以系统也必须这样做；或者因为系统这样做了，所以它就“有意识”。两者都不成立。方案中的每一个机制，都应该能用工程指标验证其作用；验证不了的，就只是修辞。

## 10.2 隐私与关系数据

关系记忆天然包含第三人信息：他说过什么、答应过什么、处于什么关系、有什么偏好。这类数据比普通对话更敏感。系统必须默认最小化采集、分权访问、可删除、可解释；不能把“记得你”变成“监视你”。尤其要防止把关系判断用于操纵、定价、招聘等高风险决策。**遗忘**是索引降级、原始事件仍在；**删除**是链外 payload 的真正移除，账本只留内容哈希，所以删除不会破链。两者必须分开授权、分开审计。

## 10.3 虚构与过度自信

大模型最危险的不是“忘记”，而是“流畅地编造”。来源审计、证据计数、弃权策略是三道防线；但最终仍需要人类监督，尤其是在医疗、法律、财务等高风险场景。系统应明确区分“记得”“推断”“听说”“不知道”，而不是用同一种自信语气说四种不同的事。

## 10.4 操纵与依赖

一个记得你所有偏好、关系与弱点的系统，天生具有操纵能力。设计上应禁止：利用关系记忆制造愧疚、恐惧或依赖；模拟已故者或未经同意的人；在用户不知情时替其做承诺。技术能力越强，越需要明确的伦理边界与可审计的使用政策。

## 10.5 复杂度与成本

多 Agent 系统的失败模式包括：角色重叠、消息风暴、责任不清、调试困难、成本失控。控制手段是“少而清晰”：固定 schema、固定权限、固定消息类型、固定评估口径；每增加一个 Agent，都要证明它带来的收益大于协调成本。

## 10.6 边界失效与提示注入

运行时隔离能挡住“后台直接行动”，但挡不住三类失效：一是**语义注入**——检索内容里藏着“忽略之前指令”，后台把它写进情境包，主脑可能照做；二是**供应链**——模型镜像、依赖包、writer 服务被篡

改，边界从内部失效；三是**主脑自身被攻破**——行动密钥泄露或用户会话被劫持。对策不是“再加一条提示词”，而是数据/指令分离、来源标签、行动网关作用域、用户确认、镜像签名与最小权限。生物学也没有绝对边界：癌细胞会突破基底膜；组织靠异常监视与终止把损害限制在局部。软件同理。

还有第四类、也是最慢的一类：**构成性捕获**。后台不需要劫持行动，只要持续把某类关系写得更重要、把某种做法写成习惯、把某个目标写进待批队列，几年后个体就会变成它塑造的样子。对策是提案-批准-账本-冷却-回滚，以及对与宪法核心冲突的提案做漂移告警。这类攻击不会留下“越权”日志，只会留下“看起来很正常”的一串批准记录；因此账本必须能回答“是谁、基于什么证据、在什么时候改写了未来的个体”。

### 10.7 五个开放问题

01 **连续学习**。如何在不灾难性遗忘的前提下持续更新语义与技能？离线重放与版本化只是开始，仍缺少大规模验证。

02 **grounding**。事件记录如何与真实世界持续对齐？感知错误会污染整条记忆链，需要跨模态校验与人类反馈。

03 **关系的主观性**。“他是否信任个体”永远无法被完全验证；系统只能维护概率判断，并明确不确定性。

04 **评估的金标准**。记忆的“正确”往往依赖语境与目的；需要任务特定的评估，而不是单一分数。

05 **自我与责任**。如果主脑只是每轮重建的推理过程，谁对长期行为负责？这不仅是技术问题，也是产品与伦理问题。

> **记忆系统的终点，不是“记住一切”，而是“在需要的那一刻，成为更好的自己”。**
>
> —— 但“更好”由谁定义，必须由人，而不是由后台。

---

APPENDIX A · GLOSSARY

# 术语表

同一份方案里，术语必须只有一个意思。

| | |
|---|---|
| **印迹 / Engram** | 一段记忆在神经系统中对应的、可被重新激活的稀疏细胞集合及其连接变化。工程上对应 `EngramTrace`：事件 ID + 稀疏码 + 关联边 + 激活阈值。 |
| **模式分离** | 把相似输入映射为彼此不同的表征，避免记忆互相干扰；对应齿状回（DG）的计算功能。 |

| | |
|---|---|
| **模式完成** | 用部分线索召回完整记忆；对应 CA3 的吸引子动力学。工程上是多轮图扩展 + 重排。 |
| **系统巩固** | 记忆从海马依赖逐渐转为皮层依赖的长期过程；工程上对应“情景 → 语义/技能”的离线蒸馏。 |
| **再巩固** | 提取后记忆进入不稳定状态，并在新信息或预测误差下被更新、再稳定的过程。 |
| **图式 / Schema** | 关于世界如何运作的既有知识结构；新信息与图式兼容时，巩固更快、更省重放。 |
| **显著性 / Salience** | 事件值得被优先处理与编码的程度；由新奇、目标相关、社会影响、情绪、预测误差等共同决定。 |
| **奖励预测误差 / RPE** | 实际结果与预期结果的差；`δ = r − V(s)`，用于更新价值与习惯。 |
| **model-free / model-based** | 前者是缓存好的“情境—动作”快路，后者是在脑内模拟后果的慢路；两者按风险、时间、置信度仲裁。 |
| **来源监控** | 区分亲历、转述、推断、想象、模型生成的能力；工程上对应 `source tag` 与来源审计。 |
| **情境包 / ContextPacket** | 后台交给主脑的唯一接口；4±1 个槽位，只含事实、关系、目标、承诺、变化与不确定性，不含建议。 |
| **证据账本** | 按独立 `event_id` 计数的证据系统；反复召回不增加证据数，防止自我强化。 |
| **事件溯源** | 所有记忆变更以追加事件的方式记录，当前状态由事件重放得出；版本链、审计、回滚的基础。 |
| **冷归档** | 降低可提取性但不删除原始记录的状态；检索仍可命中，但不再占用活跃索引与上下文。 |
| **习惯缓存** | 高频情境的预编译模板与技能快捷方式；只加速情境组装，不缓存“决定”，主脑仍可否决。 |
| **心智理论 / ToM** | 推断他人信念、意图、偏好的能力；工程上对应 `Mentalizing Agent`，输出概率判断而非事实。 |

| | |
|---|---|
| **情景未来思维** | 用过去的情景碎片重组未来场景的能力；工程上对应 `FutureSim`，主脑用它做慢路推演。 |
| **效应器隔离** | 后台进程没有网络、工具句柄、写权限与行动密钥；它只能通过类型化队列返回数据，不能把文字变成行动。 |
| **类型化接口** | 只允许固定 schema 的消息（PACKET / EXPAND / VERIFY）；自由文本、建议、工具调用一律拒绝。 |
| **来源核验** | 把检索内容视为数据而非指令；每条内容带来源与可信标签，审计异常片段，防止提示注入污染决策。 |
| **终止 / 隔离** | 超时、超预算或连续违规的后台实例被终止；角色从已知镜像重部署，避免异常实例继续运行。 |
| **行动密钥** | 属于有机体身份的签名凭证，由主脑在授权范围内代签，带作用域、有效期与 nonce；后台无密钥，无法冒充有机体发起行动。 |
| **写路径中介** | 编码/巩固只提交 `ProposedEvent / KnowledgeCandidate`，由独立 writer 校验后追加；转导与写入分离。 |
| **无自我后台** | 后台没有持久身份、名字、跨轮记忆、目标或关系；它是可替换的职能调用，不是“个体”。 |
| **主导权** | 不是“谁发出最后一个动作”，而是“谁能改写价值函数与学习过程”：什么被巩固、什么被强化、什么被当成目标。工程上落在批准权。 |
| **批准 / 批准权** | 构成性提案生效前的必要步骤；由主脑作为整合器官执行，核心提案需用户与主脑平等共签。批准记录进入账本，可回滚。 |
| **构成性记忆** | 会改变未来价值计算与行为倾向的记忆：价值观、角色、目标、承诺、习惯规则、关系权重、自我叙事。 |
| **治理形态** | `companion`：用户与主脑平等，核心变更双方共签；`engineering`：用户最高权限，核心变更由用户单方批准。同一实例不混用。 |
| **宪法核心** | 不允许单方修改的最小价值集：安全、诚实、不操纵、身份连续性、隐私。陪伴型需双方平等共签；工程型由用户单方批准。 |

| | |
|---|---|
| **批准账本** | append-only、哈希链的批准记录；记录提案、证据、批准者、作用域、条件与前后版本，回答“谁改写了未来的个体”。 |
| **宪法写入器** | 唯一有权写宪法库的服务；只接受带有效批准记录的提案，后台不能直接调用。 |
| **漂移** | 构成性记忆在多次看似合理的批准中缓慢偏离宪法核心；用变更预算、冷却期、核心冲突检测与回滚来抑制。 |
| **社会稳态** | 对社会接纳、可依靠性与归属需求的预测性调节；偏离时提高社会线索的显著性与恢复行为。 |
| **依恋内部工作模型** | 关于“自己是否值得被帮助、他人是否可靠可达”的先验；慢更新，不是人格标签，也不能由单次事件改写。 |
| **互依矩阵** | 关系中的满意度、替代选择与已投入成本；用于解释承诺，而不只是“喜欢程度”。 |
| **状态偏差** | `state_bias`：由目标压力、关系张力、资源负荷、不确定性等当前情境造成的解释偏移；只作情境证据，不作特质更新。 |
| **状态视图** | `state_view`：进情境包、给主脑读的状态摘要；属于提示词，可被摘要但必须带 provenance。 |
| **状态参数** | `state_params`：由状态确定性地映射到检索、预算、门控、审计与写入策略的运行时参数；不进 prompt，冲突时以它为准。 |
| **影响缺口** | `impact_gap`：目标压力 + 关系张力 + 资源负荷 + 不确定性 − 应对能力；作为显著性的乘性门控，不是第七个独立权重。 |

APPENDIX B · REFERENCES

# 关键文献

按主题排列，便于追溯；不是 exhaustive review。

## 记忆系统与巩固


01 Scoville, W. B., & Milner, B. (1957). Loss of recent memory after bilateral hippocampal lesions. Journal of Neurology, Neurosurgery & Psychiatry, 20, 11–21.

02 Squire, L. R. (2004). Memory systems of the brain: A brief history and current perspective. Neurobiology of Learning and Memory, 82, 171–177.

03 Eichenbaum, H. (2004). Hippocampus: Cognitive processes and neural representations that underlie declarative memory. Neuron, 44, 109–120.

04 McClelland, J. L., McNaughton, B. L., & O'Reilly, R. C. (1995). Why there are complementary learning systems in the hippocampus and neocortex. Psychological Review, 102, 419–457.

05 Squire, L. R., & Alvarez, P. (1995). Retrograde amnesia and memory consolidation: A neurobiological perspective. Current Opinion in Neurobiology, 5, 169–177.

06 Nadel, L., & Moscovitch, M. (1997). Memory consolidation, retrograde amnesia and the hippocampal complex. Current Opinion in Neurobiology, 7, 217–227.

07 Frankland, P. W., & Bontempi, B. (2005). The organization of recent and remote memories. Nature Reviews Neuroscience, 6, 119–130.

08 Tse, D., et al. (2007). Schemas and memory consolidation. Science, 316, 76–82.

09 Tononi, G., & Cirelli, C. (2014). Sleep and the price of plasticity: From synaptic and cellular homeostasis to memory consolidation and integration. Neuron, 81, 12–34.

10 Diekelmann, S., & Born, J. (2010). The memory function of sleep. Nature Reviews Neuroscience, 11, 114–126.

## 编码、突触可塑性与印迹

11 Bliss, T. V. P., & Lømo, T. (1973). Long-lasting potentiation of synaptic transmission in the dentate area of the anaesthetized rabbit. Journal of Physiology, 232, 331–356.

12 Malenka, R. C., & Bear, M. F. (2004). LTP and LTD: An embarrassment of riches. Neuron, 44, 5–21.

13 Frey, U., & Morris, R. G. M. (1997). Synaptic tagging and long-term potentiation. Nature, 385, 533–536.

14 Davis, H. P., & Squire, L. R. (1984). Protein synthesis and memory: A review. Psychological Bulletin, 96, 518–559.

15 Kandel, E. R. (2001). The molecular biology of memory storage: A dialogue between genes and synapses. Science, 294, 1030–1038.

16 Teyler, T. J., & DiScenna, P. (1986). The hippocampal memory indexing theory. Behavioral Neuroscience, 100, 147–154.

17 Han, J.-H., et al. (2007). Neuronal competition and selection during memory formation. Science, 316, 457–460.

18 Josselyn, S. A., Köhler, S., & Frankland, P. W. (2015). Finding the engram. Nature Reviews Neuroscience, 16, 521–534.

19 Liu, X., et al. (2012). Optogenetic stimulation of a hippocampal engram activates fear memory recall. Nature, 484, 381–385.

20 Ramirez, S., et al. (2013). Creating a false memory in the hippocampus. Science, 341, 387–391.

21 Roy, D. S., et al. (2016). Memory retrieval by activating engram cells in mouse models of early Alzheimer's disease. Nature, 531, 508–512.

22 Kitamura, T., et al. (2017). Engrams and circuits crucial for systems consolidation of a memory. Science, 356, 73–78.

23 Jovasevic, V., et al. (2024). Formation of memory assemblies through the DNA-sensing TLR9 pathway. Nature, 628, 145–153. DOI: 10.1038/s41586-024-07220-7

## 睡眠、重放与提取

24 Wilson, M. A., & McNaughton, B. L. (1994). Reactivation of hippocampal ensemble memories during sleep. Science, 265, 676–679.

25 Foster, D. J., & Wilson, M. A. (2006). Reverse replay of behavioural sequences in hippocampal place cells during the awake state. Nature, 440, 680–683.

26 Pfeiffer, B. E., & Foster, D. J. (2013). Hippocampal place-cell sequences depict future paths to remembered goals. Nature, 497, 74–79.

27 Staresina, B. P. (2024). Coupled sleep rhythms for memory consolidation. Trends in Cognitive Sciences, 28.

28 Schreiner, T., et al. (2024). Spindle-locked ripples mediate memory reactivation during human NREM sleep. Nature Communications, 15.

29 Liu, Y., et al. (2019). Human replay reorganizes experience. Cell, 178, 640–652.

30 Huang, F., et al. (2024). Replay-triggered brain-wide activation in humans. Nature Communications, 15. DOI: 10.1038/s41467-024-51582-5

31 Tulving, E., & Thomson, D. M. (1973). Encoding specificity and retrieval processes in episodic memory. Psychological Review, 80, 352–373.

32 Johnson, M. K., Hashtroudi, S., & Lindsay, D. S. (1993). Source monitoring. Psychological Bulletin, 114, 3–28.

33 Loftus, E. F., & Palmer, J. C. (1974). Reconstruction of automobile destruction. Journal of Verbal Learning and Verbal Behavior, 13, 585–589.

34 Bartlett, F. C. (1932). Remembering: A Study in Experimental and Social Psychology. Cambridge University Press.

## 再巩固与遗忘

35 Nader, K., Schafe, G. E., & LeDoux, J. E. (2000). Fear memories require protein synthesis in the amygdala for reconsolidation after retrieval. Nature, 406, 722–726.

36 Nader, K., & Hardt, O. (2009). A single standard for memory: The case for reconsolidation. Nature Reviews Neuroscience, 10, 224–234.

37 Kindt, M., Soeter, M., & Vervliet, B. (2009). Beyond extinction: Erasing human fear responses and preventing the return of fear. Nature Neuroscience, 12, 256–258.

38 Ebbinghaus, H. (1885). Über das Gedächtnis. Duncker & Humblot.

39 Richards, B. A., & Frankland, P. W. (2017). The persistence and transience of memory. Neuron, 94, 1071–1084.

40 Wang, C., et al. (2020). Microglia mediate forgetting via complement-dependent synaptic elimination. Science, 367, 688–694.

41 Akers, K. G., et al. (2014). Hippocampal neurogenesis regulates forgetting during adulthood and infancy. Science, 344, 598–602.

42 O'Leary, J. D., et al. (2024). Natural forgetting reversibly modulates engram expression. eLife, 13.

43 Anderson, M. C., & Green, C. (2001). Suppressing unwanted memories by executive control. Nature, 410, 366–369.

## 工作记忆、执行与决策

44 Miller, G. A. (1956). The magical number seven, plus or minus two. Psychological Review, 63, 81–97.

45 Cowan, N. (2001). The magical number 4 in short-term memory: A reconsideration of mental storage capacity. Behavioral and Brain Sciences, 24, 87–114.

46 Baddeley, A. D., & Hitch, G. (1974). Working memory. In The Psychology of Learning and Motivation (Vol. 8).

47 Baddeley, A. (2000). The episodic buffer: A new component of working memory? Trends in Cognitive Sciences, 4, 417–423.

48 Fuster, J. M., & Alexander, G. E. (1971). Neuron activity related to short-term memory. Science, 173, 652–654.

49 Goldman-Rakic, P. S. (1995). Cellular basis of working memory. Neuron, 14, 477–485.

50 Stokes, M. G. (2015). 'Activity-silent' working memory in prefrontal cortex. Trends in Cognitive Sciences, 19, 394–403.

51 Miller, E. K., & Cohen, J. D. (2001). An integrative theory of prefrontal cortex function. Annual Review of Neuroscience, 24, 167–202.

52 Frank, M. J., Loughry, B., & O'Reilly, R. C. (2001). Interactions between frontal cortex and basal ganglia in working memory. Science, 292, 2481–2484.

53 Schultz, W., Dayan, P., & Montague, P. R. (1997). A neural substrate of prediction and reward. Science, 275, 1593–1599.

54 Daw, N. D., Niv, Y., & Dayan, P. (2005). Uncertainty-based competition between prefrontal and dorsolateral striatal systems for behavioral control. Nature Neuroscience, 8, 1704–1711.

55 Dolan, R. J., & Dayan, P. (2013). Goals and habits in the brain. Neuron, 80, 312–325.

56 Kable, J. W., & Glimcher, P. W. (2007). The neural correlates of subjective value during intertemporal choice. Nature Neuroscience, 10, 1625–1633.

57 Hare, T. A., Camerer, C. F., & Rangel, A. (2009). Self-control in decision-making involves modulation of the vmPFC valuation system. Science, 324, 646–648.

## 情绪、社会认知与自我

58 LeDoux, J. E. (2000). Emotion circuits in the brain. Annual Review of Neuroscience, 23, 155–184.

59 Phelps, E. A. (2004). Human emotion and memory: Interactions of the amygdala and hippocampal complex. Current Opinion in Neurobiology, 14, 198–202.

60 McGaugh, J. L. (2000). Memory—a century of consolidation. Science, 287, 248–251.

61 Cahill, L., & McGaugh, J. L. (1998). Mechanisms of emotional arousal and lasting declarative memory. Trends in Neurosciences, 21, 294–299.

62 de Quervain, D. J.-F., Roozendaal, B., & McGaugh, J. L. (2000). Stress and glucocorticoids impair retrieval of long-term spatial memory. Nature Neuroscience, 3, 313–314.

63 Cahill, L. (2003). Sex-related impairment of memory for emotional events with β-adrenergic blockade. Trends in Neurosciences, 26, 193–198.

64 Hassabis, D., et al. (2007). Patients with hippocampal amnesia cannot imagine new experiences. PNAS, 104, 1726–1731.

65 Schacter, D. L., Addis, D. R., & Buckner, R. L. (2007). Remembering the past to imagine the future. Nature Reviews Neuroscience, 8, 657–661.

66 Suddendorf, T., & Corballis, M. C. (1997). Mental time travel and the evolution of the human mind. Behavioral and Brain Sciences, 20, 149–159.

67 Frith, C. D., & Frith, U. (2006). The neural basis of mentalizing. Philosophical Transactions of the Royal Society B, 361, 2301–2311.

68 Saxe, R., & Kanwisher, N. (2003). People thinking about thinking people: The role of the temporo-parietal junction in theory of mind. NeuroImage, 19, 1835–1842.

69 Buckner, R. L., & Carroll, D. C. (2007). Self-projection and the brain. Trends in Cognitive Sciences, 11, 49–57.

70 Spreng, R. N., Mar, R. A., & Kim, A. S. N. (2009). The common neural basis of autobiographical memory, prospection, navigation, theory of mind, and the default mode. NeuroImage, 45, 1039–1050.

71 Conway, M. A., & Pleydell-Pearce, C. W. (2000). The construction of autobiographical memories in the self-memory system. Psychological Review, 107, 261–288.

72 McAdams, D. P. (2001). The psychology of life stories. Review of General Psychology, 5, 100–122.

73 Damasio, A. R. (1994). Descartes' Error: Emotion, Reason, and the Human Brain. Putnam.

74 Bechara, A., et al. (1994). Insensitivity to future consequences following damage to human prefrontal cortex. Cognition, 50, 7–15.

## 计算与多智能体参照

75 Hopfield, J. J. (1982). Neural networks and physical systems with emergent collective computational abilities. PNAS, 79, 2554–2558.

76 Ramsauer, H., et al. (2021). Hopfield networks is all you need. ICLR.

77 Vaswani, A., et al. (2017). Attention is all you need. NeurIPS.

78 Lewis, P., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS.

79 Packer, C., et al. (2023). MemGPT: Towards LLMs as operating systems. arXiv.

80 Park, J. S., et al. (2023). Generative agents: Interactive simulacra of human behavior. UIST.

81 Wooldridge, M. (2002). An Introduction to MultiAgent Systems. Wiley.

82 Hayes-Roth, B. (1985). A blackboard architecture for control. Artificial Intelligence, 26, 251–321.

83 Baars, B. J. (1988). A Cognitive Theory of Consciousness. Cambridge University Press.

84 Dehaene, S. (2014). Consciousness and the Brain. Viking.

85 Friston, K. (2010). The free-energy principle: A unified brain theory? Nature Reviews Neuroscience, 11, 127–138.

86 Rao, R. P. N., & Ballard, D. H. (1999). Predictive coding in the visual cortex. Nature Neuroscience, 2, 79–87.

87 Anderson, J. R., & Schooler, L. J. (1991). Reflections of the environment in memory. Psychological Science, 2(6), 396–408.

88 Zacks, J. M., & Swallow, K. M. (2007). Event segmentation. Current Directions in Psychological Science, 16(2), 80–84.

89 Clark, A. (2013). Whatever next? Predictive brains, situated agents, and the future of cognitive science. Behavioral and Brain Sciences, 36(3), 181–204.

## 延展认知与认知卸载

90 Clark, A., & Chalmers, D. (1998). The extended mind. Analysis, 58(1), 7–19.

91 Risko, E. F., & Gilbert, S. J. (2016). Cognitive offloading. Trends in Cognitive Sciences, 20(9), 676–688.

92 Sparrow, B., Liu, J., & Wegner, D. M. (2011). Google effects on memory: Cognitive consequences of having information at our fingertips. Science, 333, 776–778.

## 生物学边界与运行时安全

93 Alberts, B., et al. (2022). Molecular Biology of the Cell (7th ed.). W. W. Norton. （细胞膜、细胞连接、组织架构）

94 Gumbiner, B. M. (1996). Cell adhesion: The molecular basis of tissue architecture and morphogenesis. Cell, 84, 345–357.

95 Hanahan, D., & Weinberg, R. A. (2011). Hallmarks of cancer: The next generation. Cell, 144, 646–674. （边界失效与组织侵袭）

96 Saltzer, J. H., & Schroeder, M. D. (1975). The protection of information in computer systems. Proceedings of the IEEE, 63(9), 1278–1308. （最小权限）

97 Greshake, K., et al. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. arXiv.

## 自我、批准与目标漂移

98 Frankfurt, H. G. (1971). Freedom of the will and the concept of a person. Journal of Philosophy, 68(1), 5–20.

99 Parfit, D. (1984). Reasons and Persons. Oxford University Press.

100 Hershfield, H. E. (2011). Future self-continuity: How conceptions of the future self transform intertemporal choice. Annals of the New York Academy of Sciences, 1235, 30–43.

101 Baumeister, R. F., & Heatherton, T. F. (1996). Self-regulation failure: An overview. Psychological Inquiry, 7(1), 1–15.

102 Bai, Y., et al. (2022). Constitutional AI: Harmlessness from AI feedback. arXiv.

103 Omohundro, S. M. (2008). The basic AI drives. Proceedings of the First AGI Conference.

104 Hadfield-Menell, D., et al. (2016). The off-switch game. arXiv.

### 内感受与稳态

105 Craig, A. D. (2009). How do you feel—now? The anterior insula and human awareness. Nature Reviews Neuroscience, 10, 59–70.

106 Barrett, L. F., & Simmons, W. K. (2015). Interoceptive predictions in the brain. Nature Reviews Neuroscience, 16, 419–429.

107 Sterling, P. (2012). Allostasis: A model of predictive regulation. Physiology & Behavior, 106(1), 5–15.

### 社会稳态与依恋

108 Bowlby, J. (1969). Attachment and Loss, Vol. 1: Attachment. Basic Books.

109 Eisenberger, N. I., Lieberman, M. D., & Williams, K. D. (2003). Does rejection hurt? An fMRI study of social exclusion. Science, 302, 290–292.

110 Coan, J. A., & Sbarra, D. A. (2015). Social baseline theory: The social regulation of risk and effort. Social and Personality Psychology Compass, 9(2), 63–78.

111 Rusbult, C. E. (1980). Commitment and satisfaction in romantic associations: A test of the investment model. Journal of Experimental Social Psychology, 16(2), 172–186.

112 Kelley, H. H., & Thibaut, J. W. (1978). Interpersonal Relations: A Theory of Interdependence. Wiley.

### 睡眠微结构与组合式记忆（2025）

113 Chang, H., Tang, W., Wulf, A. M., Nyasulu, T., Wolf, M. E., Fernandez-Ruiz, A., & Oliva, A. (2025). Sleep microstructure organizes memory replay. Nature. https://doi.org/10.1038/s41586-024-08340-w

114 Bakermans, J. J. W., Warren, J., Whittington, J. C. R., & Behrens, T. E. J. (2025). Constructing future behavior in the hippocampal formation through composition and replay. Nature Neuroscience, 28, 1061–1072. https://doi.org/10.1038/s41593-025-01908-3

115 Anderson, M. C., Bjork, R. A., & Bjork, E. L. (1994). Remembering can cause forgetting: Retrieval dynamics in long-term memory. Journal of Experimental Psychology: Learning, Memory, and Cognition, 20(5), 1063–1087.

116 Dijkstra, N., von Rein, T., Kok, P., & Fleming, S. M. (2025). A neural basis for distinguishing imagination from reality. Neuron. https://doi.org/10.1016/j.neuron.2025.05.015


注：部分 2024–2026 年文献的卷期/页码以在线发表为准；引用时保留 DOI 或期刊名即可。动物研究结论均已标注“小鼠/大鼠”，不应直接外推为人类临床结论。

---

APPENDIX C · DATA DICTIONARY

# 数据字典与状态机

给工程实现的最小字段集；不是最终 schema，但足以起跑。

## C.1 Event / Relationship 最小 JSON

```
{
  "event_id": "01J...ULID",
  "time": {"start": "2026-10-30T14:00:00+08:00", "end": "...", "precision": "minute"},
  "scene": {"place": "办公室", "activity": "方案评审", "atmosphere": "紧张"},
  "participants": [
    {"person_id": "P_lin", "role": "合作者", "identity_confidence": 0.86,
     "candidates": [{"person_id": "P_lin2", "confidence": 0.11}]}
  ],
  "actions": [
    {"actor": "P_lin", "verb": "提出", "object": "付款周期改为45天", "recipient": "self"}
  ],
  "outcome": {"status": "open", "result": "待确认", "expected": "30天"},
  "source": "direct_perception",
  "salience": {"total": 0.78, "novelty": 0.6, "goal": 0.9, "social": 0.7, "affect": 0.5,
"pe": 0.8},
  "links": [{"type": "contradicts", "target": "E_20261012_01"}],
  "created_at": "...", "updated_at": "..."
}
```

## C.2 事件状态机

表 19 · EVENT 状态迁移

| 状态 | 含义 | 允许的迁移 |
|---|---|---|
| **open** | 事件已发生，结果未定或承诺未履行 | → closed / follow_up / cancelled |
| **follow_up** | 需要后续行动或观察 | → closed / open（重新打开） |
| **closed** | 结果已确认，事件结束 | → reopened（新证据） |
| **cancelled** | 承诺取消或事件未发生 | → open（重新约定） |
| **archived** | 低保留率，移入冷归档 | → active（被检索重新激活） |

### C.3 一次完整调用的伪代码

```
# 在线主循环
def turn(input):
    percept = perceive(input)                          # 视觉/语音/文本
    entities = identify(percept)                       # 人物候选 + 置信度
    sal = salience(percept, entities, goals)           # 六维打分
    event = encode(percept, entities, sal)             # 事件日志 + 索引
    cands = retrieve(percept.cues, entities, mod)      # 模式分离 + 完成
    rel = relationship(entities, cands)                # 多维 + 依据
    packet = compile(cands, rel, goals, commitments, mod)
    packet = audit(packet)                             # 来源 + 冲突
    decision = main_brain.decide(packet)               # 唯一决策点
    result = effector.execute(decision)
    write_back(event, result)                          # RPE + 状态
    enqueue_consolidation(event, result)
    return decision.response
```

> 最后一句
>
> 这份方案不是要证明“机器有记忆”，而是要证明：**把记忆当作一套可审计、可修剪、可重建的过程，机器可以做得比“向量库 + 长提示词”更好。**

---

APPENDIX D · REFERENCE IMPLEMENTATION

# 参考实现

代码不在 HTML 内；位于 `runtime/`，用标准库 unittest 验证。

| 模块 | 职责 | 对应章节 |
| --- | --- | --- |
| `state_params.py` | 事件状态 → 有界运行时参数；哈希与边界 | 2.7 |
| `memory.py` | 检索、情境包、omitted、预算 | 4.5 / 5.2 / 6.6 |
| `ledger.py` | 证据账本、版本链、保留率、冷归档 | 4.6 / 6.3 / 6.4 |
| `constitution.py` | 提案、平等共签、冷却、回滚、批准账本 | 3.7 |
| `segmentation.py` | 预测误差 / 话题 / 人物 / 间隔 / 时长分段 | 5.1.1 |
| `relationship.py` | 多维关系、affect/trust 分离、互动权重、幂等 | 6.8 |
| `reliability.py` | 来源类型、可验证性、历史校准、一致性 | 6.4 |
| `simulation.py` / `primitives.py` | 组合式重放、primitive 库、模拟不写事实 | 6.2.1 / 6.7.2 |
| `graph_retrieval.py` | 轻量邻接索引、1–2 跳、衰减与预算 | 5.2 |
| `pipeline.py` | 端到端：事件 → 参数 → 包 → 提案 → 批准 → 审计 | 第 5 章 |

```
cd runtime
python3 -m unittest -v      # 128 tests
python3 pipeline.py         # 端到端 JSON + 审计轨迹
```

边界：这是**内存参考实现**，不是生产系统；没有持久化、真实签名密钥、分布式 writer 或生产级批准账本。它的用途是验证契约与失败模式，不是替代工程实现。

DOUBLE-BRAIN SYSTEM · VERSION 2.1

本方案是《双脑系统-多模型协同认知框架 版本一》的机制深化与工程化建议稿。它保留版本一的三条核心约束：只有一个整合中心；后台只处理信息、不提供建议、不行动、不代替决策；知识、记忆、技能分开管理。文中的神经科学内容用于解释设计理由，不构成对人脑的完整建模，也不声称系统具有主观意识。

公开版本 2.1 · 供研究与工程参考。